
Edge AI 기반 적응형 칼만 필터의 임베디드 실시간 적용 연구

제출일 : 2026 년 05 월 29 일

지도교수 : 손경락 교수님

정보통신공학과	202202928	임다영
정보통신공학과	202301413	신유빈

Edge AI 기반 적응형 칼만 필터의 임베디드 실시간 적용 연구

대 학 : 공 과 대 학

학 과 : 정보통신공학과

학 번 : 202202928

성 명 : 임다영

202301413

신유빈

이 논문을 제출 하오니 승인하여 주십시오.

2026 년 5 월 29 일

성 명 : 임다영

신유빈

위 학생의 논문 제출을 승인함.

2026 년 5 월 29 일

지 도 교 수 : 손경락

요 약

Cyber-Physical System의 액추에이터 제어는 자원이 제한된 MCU 계층에서 수행되므로, 페루프의 출발점인 센서 노이즈를 MCU 내부에서 보정하는 경량 추정 기법이 요구된다. 본 논문은 STM32F446RE MCU 환경에서 동작하는 Edge AI 기반 적응형 칼만 필터의 임베디드 실시간 적용을 다룬다. 저속 주차 보조 시스템의 정밀 거리 추정을 응용 대상으로 하여, VL53L0X ToF 센서를 주 측정 채널로, FIT0450 엔코더를 예측 입력으로, HC-SR04 초음파 센서를 TinyML 보조 feature로 사용하는 적응형 상태 추정 시스템을 구현하였다. Fixed Kalman Filter, Covariance Matching 기반 적응형 칼만 필터(CM-AKF), 6-feature MLP 기반 TinyML 적응형 칼만 필터(TinyML-AKF, INT8 양자화 257 파라미터)를 동일 MCU에서 병렬 실행하여 정확도와 실시간성을 비교 분석하였다. 30 분 $\times$ 3 run 정적 안정성 시나리오에서 누적 242,992회 추론의 평균 추론 시간 35.32 μ s(200 Hz 제어 루프 예산 5 ms의 0.71%), run-to-run 표준편차 0.007 μ s로 결정론적(deterministic) 실시간 동작을 입증하였다. 알루미늄 동적 차단 시나리오에서 두 적응형 알고리즘이 Fixed KF 대비 약 1/3 수준의 위치 추정 RMSE를 달성하였으며, TinyML-AKF는 차단 이탈 후 R 추정값이 CM-AKF 대비 약 2.7배 빠르게 회복되는 거동을 보였다. 또한 미지 표면(회색 단면 우드락) 일반화 검증에서 TinyML-AKF가 학습 분포 외 조건에서도 발산 없이 동작함을 확인하였다.

주요어: Adaptive Kalman Filter, TinyML, Edge AI, STM32, ToF 센서, 임베디드 시스템

1장 서론

1.1 연구 주제

본 연구의 주제는 “Edge AI 기반 적응형 칼만 필터의 임베디드 실시간 적용 연구”이다. 로봇 시스템, 모바일 플랫폼, 산업 자동화 장치 등 사이버-물리 시스템(Cyber-Physical System)에서는 환경 상태를 정확하게 추정하는 것이 시스템 안정성과 제어 성능의 핵심이다. 특히 자율주차 및 주차 보조 시스템은 시스템이 슬롯에 진입하는 마지막 단계에서 저속으로 벽 또는 인접 차량까지의 거리를 실시간으로 정밀하게 추정해야 한다. 이때 액추에이터(조향·제동) 제어는 자원이 제한된 MCU 기반 임베디드 계층에서 수행되므로, 페루프 출발점인 거리 센서의 노이즈를 MCU 내부에서 보정할 수 있는 경량 추정 기법이 요구된다.

이러한 거리 추정에는 초음파 센서, Time-of-Flight(ToF) 센서, 엔코더 등 서로 다른 특성을 가진 센서가 활용되지만, 실제 센서 데이터에는 노이즈와 측정 오차가 불가피하게 포함되며, 그 크기는 표면 재질이나 주변 환경에 따라 변동한다. 이러한 불확실성 속에서 신뢰할 수 있는 상태 추정을 수행하기 위해, 예측 모델과 센서 측정값을 확률적으로 결합하는 상태 추정(state estimation) 기법이 널리 활용되고 있다.

Kalman Filter (KF)는 예측 모델과 센서 측정값을 결합하여 시스템 상태를 확률적으로 추정하는 대표적인 알고리즘으로, 로봇 항법 및 차량 위치 추정 분야에서 널리 사용된다. 그러나 일반적인 Kalman Filter는 측정 노이즈 공분산(R)과 프로세스 노이즈 공분산(Q)을 고정된 값으로 설정하기 때문에, 실제 환경에서 변화하는 센서 노이즈 특성을 충분히 반영하지 못하는 한계가 있다. 이를 해결하기 위해 센서 잔차(residual)나 통계적 특성을 이용하여 필터 파라미터를 동적으로 조정하는 Adaptive Kalman Filter (AKF)가 제안되었다 [1][2][3].

기존의 규칙 기반(Rule-based) Adaptive KF는 잔차 통계 등 제한된 정보에 기반한 단일 적응 규칙에 의존하기 때문에, 환경이 바뀔 때마다 반복적인 파라미터 튜닝이 필요하고, 복잡한 노이즈 패턴에 대한 일반화 능력이 부족하다. 최근에는 인공지능 연산을 클라우드가 아닌 장치 자체에서 수행하는 Edge AI 기술이 발전하면서, MCU와 같은 제한된 환경에서도 경량화된 머신러닝 모델을 실행할 수 있는 TinyML 기반 접근 방식이 등장하였다 [4][5].

그러나 기존 연구들은 대부분 시뮬레이션 환경이나 고성능 컴퓨팅 환경에서 수행되었으며, STM32와 같은 자원이 제한된 MCU 기반 임베디드 시스템에서 Edge AI와 Adaptive Kalman Filter를 결합하여 실제로 구현하고 성능을 비교 분석한 연구는 상대적으로 부족한 상황이다.

따라서 본 연구에서는 STM32F446RE (ARM Cortex-M4, 180 MHz, FPU 탑재) 기반 임베디드 환경에서 Time-of-Flight 거리 센서(VL53L0X)를 칼만 필터의 주 측정 센서로 사용하고, FIT0450 엔코더를 KF 예측 단계의 운동학적 입력으로, HC-SR04 초음파 센서를 TinyML 모델의 보조 feature 입력(sensor disagreement)으로 활용하는 적응형 상태 추정 시스템을 구축한다. 특히 ToF 센서의 경우 표면 반사율 변화에 따라 signal rate가 급격히 변하며, 이로 인해 동일 환경에서도 측정 노이즈 특성이 비정상적으로 변화한다. 기존 고정 KF는 이러한 변화를 반영하지 못하며, 잔차 기반 AKF 역시 잔차가 실제로 증가한 후에야 대응하므로 선행 신호를 활용할 수 없다. VL53L0X 센서는 표면 특성에 따라 signal rate가 변화하는 특성을 가지므로, 센서 신뢰도 변화에 따른 Adaptive Kalman Filter의 동작을 평가하기에 적합하다. 또한 Fixed Kalman Filter, Covariance Matching 기반 Adaptive Kalman Filter (CM-AKF), TinyML 기반 Adaptive Kalman Filter (TinyML-AKF)를 구현하고 이들의 성능을 비교·분석하는 것을 목표로 한다.

본 연구는 실제 자율주차 시스템 전체를 구현하기보다는, 저속 주차 접근 구간에서의 정밀 거리 추정 문제를 축소 모델(scale-down model) 형태로 단순화하여, 제한된 MCU 환경에서 Adaptive Kalman Filter의 적응 메커니즘과 Edge AI 기반 적용 가능성을 실험적으로 검증하는 데 목적이 있다.

본 연구는 다음의 세 연구 질문에 답하고자 한다.

RQ1. STM32F446RE MCU 환경에서 TinyML 기반 측정 노이즈 공분산(R) 추정이 200 Hz 제어 루프의 시간 제약 내에서 실시간 동작 가능한가?

RQ2. TinyML-AKF는 CM-AKF 대비, 복합 노이즈가 존재하는 시나리오(E2, E3, E5)에서 위치 추정 정확도와 R 추정 거동 측면에서 어떠한 차이를 보이는가?

RQ3. Signal rate, sensor disagreement 등 다변량 feature의 활용은 잔차 통계만을 사용하는 기존 적응 기법 대비 복합 노이즈 환경에서 어떠한 이점을 제공하는가?

1.2 Edge 환경에서 AI 기반 Adaptive KF의 필요성

규칙 기반 Adaptive KF도 Edge 환경에서 동작 가능하지만, AI 기반 접근이 유리할 것으로 예상되는 조건은 다음과 같다. 본 연구는 이러한 우위가 실제 STM32 환경에서도 성립하는지를 실험적으로 검증한다.

본 연구에서 '실시간(real-time)'은 두 가지 의미를 모두 포함한다. 첫째는 hard real-time으로, MCU의 TinyML 추론과 KF 갱신이 메인 제어 루프의 시간 제약(<5 ms) 내에 완료됨을 의미한다. 둘째는 online streaming으로, 센서 갱신 주기(VL53L0X 50 Hz, 엔코더 200 Hz)에 동기되어 센서 → feature → 추론 → KF Update → 위치 추정의 전체 사이클이 데이터 흐름에

따라 즉시 갱신됨을 의미한다. 전자는 MCU 실행 추론 시간으로(4.3절), 후자는 통합 펌웨어의 라이브 동작 검증으로(5장) 각각 입증한다.

1. **복합적 노이즈 패턴:** 단일 센서 이상이 아닌, 여러 센서가 동시에 영향을 받는 복합 상황에서는 다변량 feature 를 종합적으로 고려하는 ML 모델이 단순 임계값 규칙보다 정확한 R 값 추정이 가능하다.
2. **환경 전이 적응:** 학습 데이터에 다양한 환경 조건을 포함시키면, 새로운 환경에서도 별도의 재튜닝 없이 일반화된 R 값 추정이 가능하다. 이는 규칙 기반 방식의 가장 큰 약점인 '환경별 반복 튜닝' 문제를 해결한다.
3. **비선형 노이즈-파라미터 매핑:** 실제 센서 노이즈와 최적 R 값 사이의 관계는 비선형적일 수 있으며, 신경망은 이러한 비선형 매핑을 학습할 수 있다.

본 연구는 측정 노이즈 공분산 R 의 적응에 범위를 한정하며, 프로세스 노이즈 공분산 Q 는 고정한다. 이는 본 연구가 대상으로 하는 “주차 슬롯 진입 마지막 단계의 저속 정밀 거리 추정”의 특성에서 비롯된 설계 결정이다. 해당 구간에서 로봇은 저속의 등속 직선 운동을 수행하며, 운동 모델(등속 모델)의 불확실성은 주행 중 시간에 따라 변하지 않는다. 반면 센서 신뢰도는 벽 표면 반사율 변화(E2), 시야각의 일시적 차단(E3), 학습되지 않은 표면(E5) 등 측정 환경 요인에 의해 시간에 따라 크게 변동한다. 즉 본 시나리오에서 적응이 필요한 시변(time-varying) 요소는 측정 노이즈 R 이며, 프로세스 노이즈 Q 는 적응 대상이 아니다. 이는 적응형 칼만 필터 문헌에서 측정 환경 변화에 대응하는 R-적응 계열에 해당하며 [2], 본 연구의 feature 집합(잔차 통계, sensor disagreement, signal rate) 또한 모두 측정 측 신호로서 R 추론과 인과적으로 직결된다.

아울러 본 실험은 수동 구동을 채택하여 모터 노이즈 및 직진 편차 등 운동 측 외란을 의도적으로 통제하였으므로(4.1절), Q 고정은 실험 설계 전반과도 일관된다. 다만, AI 기반 접근은 추가 연산 비용이 발생하므로, MCU에서의 실시간성 확보가 전제 조건이다. 본 연구에서 사용할 2륜 구동 모바일 시스템의 설계 제어 주기를 200 Hz (5 ms)로 설정한다. 이 주기는 ToF 센서의 측정 갱신 주기(~50 Hz, 20 ms)에 대해 정수배($\times 4$)로 정합되어 KF Predict와 Update의 위상 정렬을 단순화하며, 일반적인 저속 모바일 로봇 제어 대역폭(수십~수백 Hz)의 상한 부근에 위치한다. 이때 TinyML 모델 추론은 전체 시간 예산의 약 10% 수준인 0.5 ms 미만을 목표로 하며, 나머지 4.5 ms 이내에서 센서 읽기, feature 계산, Kalman Filter 갱신, 제어 출력이 완료되는지를 검증한다.

본 연구에서는 TinyML 모델 학습을 위해 실험 환경에서 센서 데이터를 수집하여 학습 데이터셋을 구축한다. 수집된 데이터에는 Residual, Residual Variance, Residual Mean, Sensor

Disagreement, Measurement Rate, Signal Rate의 6개 feature가 포함된다. 여기서 Sensor Disagreement는 주센서와 보조센서 추정치의 차이를, Measurement Rate는 최근 윈도우 내 정상 측정 업데이트 비율을 의미한다. Signal Rate는 VL53L0X의 반사 신호 세기를 나타내며, 표면 반사율 변화 시 잔차가 커지기 전에 먼저 변화하는 선행 지표(leading indicator)로 가정한다. 이 가정의 유효성은 E3(동적 차단) 실험에서 signal rate와 잔차 시계열의 시간 선후 관계를 분석하여 실증적으로 검증한다.

각 데이터 샘플에 대해 Covariance Matching 기반 방식으로 추정된 측정 노이즈 공분산 R 값을 offline pseudo-label로 생성하고, 이를 지도 학습에 사용하여 TinyML 모델이 센서 상태에 따라 적절한 R 값을 추론하도록 설계한다. 여기서 Covariance Matching은 학습용 라벨 생성기이며, 실시간 운용 단계에서는 해당 공식을 직접 계산하지 않고 학습된 TinyML 모델이 R 값을 즉시 추론한다.

Pseudo-label은 Covariance Matching 기법을 기반으로 생성하며, 구체적인 산출 공식과 윈도우 설정은 3장 3.5.4절에서 기술한다.

1.3 실험 시나리오 및 평가 설계

본 연구는 세 가지 적응 알고리즘(Fixed KF, CM-AKF, TinyML-AKF)을 비교하기 위해 총 6개 시나리오를 설계한다. E0는 Python 합성 데이터를 이용한 KF의 정상 수렴 검증 시뮬레이션이며, E1은 정상 주차 접근 baseline, E2는 벽 반사율 변화, E3는 ToF 시야각 차단, E4는 정적 장기 안정성, E5는 미지 벽 재질 일반화 시나리오이다. 각 시나리오의 물리적 조건과 평가 지표는 4.2절 [표 4-4]에 상세히 기술한다.

모든 비교 실험은 동일한 센서 데이터 스트림, 동일한 샘플링 주기, 동일한 초기값, 동일한 센서 캘리브레이션 조건에서 수행되며, 동일한 STM32 임베디드 플랫폼에서 각 상태 추정 방법의 성능을 공정하게 비교한다. 정확도 지표(RMSE, MAE)는 별도로 확보한 기준 위치/거리값(ground truth) 대비 계산한다.

E4 실험의 30분 연속 정적 측정은 주차 후 정차 대기 상태의 거리 모니터링을 모사하는 시간 규모이며, 200 Hz 제어 루프 기준 약 360,000회의 KF 갱신 반복(50 Hz 데시메이션 로깅 기준 약 90,000 샘플)을 통해 메모리 누수, 추론 지연 누적, R 값 drift 등 임베디드 시스템의 장기 안정성 지표를 검증하기에 충분한 규모이다.

또한 TinyML 모델의 feature 설계 타당성을 검증하기 위한 ablation study를 수행하며, 구체적인 설계는 4.4절에서 기술한다.

1.4 연구 목적

본 연구의 목적은 다음과 같다.

1. STM32F446RE 기반 임베디드 시스템에서 VL53L0X를 KF 측정 센서로, FIT0450 엔코더를 KF 예측 입력으로 사용하고, HC-SR04를 TinyML 적응 모델의 보조 feature로 활용하는 적응형 상태 추정 시스템을 구현한다. 구동부는 TB6612FNG H-Bridge 기반 모터 드라이버와 FIT0450 DC geared motor로 구성한다.
2. 고정 Kalman Filter와 Covariance Matching 기반 Adaptive Kalman Filter (CM-AKF)를 구현하여 baseline 성능을 확보한다.
3. TinyML 기반 경량 신경망 모델을 설계하여 센서 특징(feature)으로부터 측정 노이즈 공분산(R)을 실시간으로 추정하는 Edge AI 기반 Adaptive Kalman Filter 구조를 구현한다. 모델은 Multi-Layer Perceptron (MLP) 구조로 설계하고 INT8 양자화를 적용하여 MCU 환경에서의 실시간 추론 가능성을 검증한다. 구체적 모델 설계는 3장 3.5절에서 기술한다.
4. Raw 센서 데이터, Fixed KF, CM-AKF, TinyML-AKF의 네 가지 방법에 대해 RMSE, MAE, 잔차 통계, 모델 추론 latency, 전체 시스템 latency, Max Error, drift, divergence 여부, 메모리 사용량(Flash 점유율), 메인 루프 시간 비율을 비교·분석한다.

본 연구는 새로운 필터 알고리즘을 제안하기보다는 MCU 자원 제약 환경에서 다양한 상태 추정 방법을 실제 임베디드 시스템에 구현하고 Edge AI 기반 접근의 적용 가능성과 한계를 실험적으로 검증하는 실용적 연구라는 점에서 의의를 가진다.

1.5 연구 기여

본 연구의 주요 기여는 다음과 같다.

1. STM32F446RE 기반 임베디드 환경에서 TinyML 기반 Adaptive Kalman Filter를 실제 하드웨어에 구현한다.
2. Raw 센서 데이터, Fixed Kalman Filter, Covariance Matching Adaptive Kalman Filter (CM-AKF), TinyML 기반 Adaptive Kalman Filter (TinyML-AKF)의 네 가지 상태 추정 방법을 동일한 MCU 환경에서 비교한다.
3. 다양한 센서 노이즈 시나리오(노이즈 스파이크, 센서 오류, 표면 반사율 변화 등)에서 각 방법의 성능을 실험적으로 평가한다.
4. TinyML 기반 접근이 전체 제어 루프 목표(<5 ms) 내에서 동작 가능한지,

그리고 모델 추론 latency가 <0.5 ms 수준으로 확보되는지를 함께 검증하여 Edge AI 기반 상태 추정의 실제 적용 가능성을 분석한다.

2 장 관련 기술 동향

2.1 Kalman Filter 기반 상태 추정

Kalman Filter (KF)는 선형 동적 시스템의 상태를 확률적으로 추정하기 위한 대표적인 재귀 알고리즘이다. 센서 노이즈가 존재하는 환경에서 시스템 모델과 관측값을 결합하여 최소 분산 추정을 수행하며, 예측(Prediction)과 보정(Update)의 두 단계를 반복 수행한다 [1][6].

본 연구는 1차원 선형 시스템을 대상으로 하므로, 상태 변수 및 파라미터가 스칼라로 축소된다. 1D KF의 재귀 구조는 다음과 같다.

Prediction 단계:

$$\hat{x}_{k|k-1} = \hat{x}_{k-1|k-1} + \Delta t \cdot u_k$$

$$P_{k|k-1} = P_{k-1|k-1} + Q$$

Update 단계:

$$K_k = \frac{P_{k|k-1}}{P_{k|k-1} + R}$$

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \cdot (z_k - \hat{x}_{k|k-1})$$

$$P_{k|k} = (1 - K_k) \cdot P_{k|k-1}$$

여기서 $\hat{x}$ 는 상태 추정값, P 는 오차 공분산, K 는 Kalman Gain, z 는 센서 측정값, F 는 상태 전이 계수, B 는 제어 입력 계수, Q 는 프로세스 노이즈 공분산, R 은 측정 노이즈 공분산이다. 본 연구의 ToF 센서는 로봇의 위치를 직접 측정하므로 관측 모델은 $H = 1$ 이며, 이에 따라 위 Update 식에서 H 가 생략된 형태로 표현된다. Kalman Gain K 는 예측 불확실성(P^-)과 측정 불확실성(R)의 상대적 비율에 따라 센서 신뢰도를 자동으로 조절하는 역할을 수행한다.

이러한 재귀적 구조는 과거의 전체 데이터를 저장할 필요 없이 이전 단계의 추정값만으로 갱신이 가능하므로, 실시간 임베디드 시스템에서 계산 효율성이 높다. KF는 로봇 시스템, 자율주행, 위치 추정, 객체 추적 등 다양한 분야에서 센서 융합의 핵심 알고리즘으로 활용되고 있다.

비선형 시스템에서는 Extended Kalman Filter (EKF)와 Unscented Kalman Filter (UKF)가 널리 사용되나 [7], 본 연구의 대상 시스템은 직선 주행 로봇의 1D 위치 추정이며, 엔코더 기반 등속 모델의 선형 근사가 유효한 범위이므로 표준 KF를 기본 필터로 채택하였다. 비선형 확장은 향후 연구로 남긴다.

2.2 Adaptive Kalman Filter

2.2.1 고정 파라미터의 한계

표준 KF는 프로세스 노이즈 공분산 Q 와 측정 노이즈 공분산 R 을 사전에 고정된 값으로 설정한다. 이 설정이 실제 환경과 일치하는 경우 최적의 추정 성능을 보장하지만, 센서 노이즈 특성이 시간에 따라 변화하는 실제 운용 환경에서는 필터 성능이 저하된다. Adaptive Kalman Filter (AKF)는 이러한 한계를 극복하기 위해 노이즈 공분산을 실시간으로 동적 조정하는 방법이다.

2.2.2 Adaptive KF 방법론 분류

기존 Adaptive KF 연구는 조정 방식에 따라 [표 2-1]과 같이 분류할 수 있다.

[표 2-1] Adaptive Kalman Filter 방법론 분류

분류	원리	대표 연구
Innovation-based	잔차(innovation)의 통계적 특성 (평균, 공분산)을 이용하여 R 또는 Q 를 실시간으로 추정	Mehra (1970) [2], Mohamed & Schwarz (1999) [3]
Covariance Matching	이론적 잔차 공분산과 실측 잔차 공분산을 일치시키는 방향으로 파라미터를 조정	Mehra (1970) [2], Myers & Tapley (1976) [15]
Multiple Model	서로 다른 노이즈 가정을 가진 다수의 KF를 병렬 실행하고 확률적으로 결합	IMM (Interacting Multiple Model)
Variational Bayesian	변분 베이저안 추론을 통해 노이즈 공분산의 사후 분포를 추정	Sarkka & Nummenmaa (2009) [16], Zhou et al. (2025) [8]
ML/DL 기반 (본 연구)	머신러닝 모델을 이용하여 센서 데이터 특성으로부터 최적 노이즈 파라미터를 학습/추론	KalmanNet (Revach et al., 2022) [9], 본 연구

본 연구는 Innovation-based 접근을 ML로 대체/보강하는 방식에 해당하며, 잔차 통계를 feature로 사용하여 R 값을 회귀 추정하는 구조를 채택한다.

2.2.3 Covariance Matching과 본 연구의 연관

상기 분류 중 Covariance Matching 기법은 본 연구의 학습 데이터 생성에 직접적으로 활용된다. 이론적으로 잔차(innovation) $v_k = z_k - \hat{x}_{k|k-1}$ 의 공분산은 $S = H \cdot P_{k|k-1} \cdot H^T + R$ 을 만족해야 한다. (본 연구의 1D 스칼라 모델에서 $H = 1$ 이므로 위 일반형이 단순화된 형태이다). Covariance Matching은 실측 잔차의 슬라이딩 윈도우 표본 분산 σ_v^2 를 계산한 뒤, 이를 S 의 추정값으로 사용하여 R 을 역산하는 방식이다. 본 연구에서는 이 원리를 활용하여 윈도우 크기 $W=20$ 으로 산출한 잔차 분산을 TinyML 모델의 pseudo-label(학습 목표값)로 사용한다. 즉, Covariance Matching의 통계적 추정 결과를 ML 모델이 학습하는 구조이며, 이를 통해 통계적 방법의 추정 지연 없이 특징(feature) 입력만으로 R 을 즉시 추론할 수 있도록 한다.

본 연구에서 Rule-based AKF는 Covariance Matching 방식을 실시간 제어 루프에 직접 적용하여 R 을 갱신하는 방법으로 구현한다. 규칙 기반 적응 기법은 잔차 분산의 임계값에 기반한 IF-ELSE 규칙 등 여러 형태로 구현될 수 있으나, 임계값 기반 규칙은 그 임계값의 설정에 따라 성능이 달라지므로 baseline으로서 공정성에 한계가 있다. 본 연구는 TinyML-AKF와의 비교 기준을 보수적으로 설정하기 위하여, AKF 문헌에서 표준적으로 사용되며 임의의 임계값에 의존하지 않는 Covariance Matching 방식 [2]을 채택하였다. Covariance Matching은 잔차 제공 평균으로부터 R 을 이론적으로 추정하므로 규칙 기반 적응의 상한(upper bound) 성능을 대표할 수 있으며, 이를 통해 TinyML 기반 AKF가 이론적으로 최적인 규칙 기반 방법 대비에서도 개선을 달성하는지를 검증한다.

한편, Covariance Matching 방식은 잔차 제공 평균이라는 단일 통계에만 의존하므로, 센서 고장과 같이 잔차가 일관되게 큰 상황에서는 적응이 오히려 역효과를 낼 수 있다. 본 연구의 사전 검증 단계(E0)에서 합성 데이터를 이용해 stuck sensor 시나리오를 모사한 결과, CM-AKF는 R 을 증가시켜 센서를 불신하지만, 이때 측정에 의한 공분산 보정이 약해져 P 가 누적되고, 누적된 P 가 칼만 게인을 다시 끌어올리는 $R \rightarrow K \rightarrow P \rightarrow R$ 순환 현상이 관찰되었으며, 그 결과 Fixed KF 대비 RMSE가 약 23% 열화되었다(합성 데이터 $\sigma_{meas} = 20$ mm 조건에서 229 mm vs 186 mm). 이는 잔차 통계 단일 지표 의존이라는 CM-AKF의 구조적 한계를 보여주며, TinyML-AKF가 sensor disagreement, signal rate 등 다변량 feature를 통해 이를 보완해야 한다는 본 연구의 동기를 뒷받침한다. 해당 가설은 4.2절의 E3 실물 시나리오에서 실험적으로 검증된다.

2.3 상태 추정을 위한 경쟁 기술 비교

Kalman Filter 외에도 다양한 상태 추정 기법이 존재하며, 각 방법의 특성을 아래에 정리한다.

[표 2-2] 상태 추정 알고리즘 비교

방법	장점	단점	계산 복잡도 MCU	적합성
Kalman Filter	최소 분산 추정, 재귀적 구조, 높은 계산 효율성	선형/가우시안 가정 필요, 고정 파라미터 한계	$O(n^3)$	매우 높음
Particle Filter	비선형/비가우시안 환경 처리 가능	샘플 수에 비례한 높은 계산량, 메모리 과다 사용	$O(N \cdot n^2)$	낮음
Complementary Filter	계산 구조 매우 단순, 구현 용이	시스템 모델 미반영, 정확도 제한	$O(n)$	높음
Luenberger Observer	모델 기반 안정적 추정 구조	확률적 노이즈 모델 미고려	$O(n^2)$	높음

n 은 상태 벡터 차원, N 은 파티클 수. 본 연구의 1D KF 구현에서는 $n = 1$ 이므로 행렬 연산이 스칼라 연산으로 축소되어 실질적 복잡도는 $O(1)$ 로 축소된다.

계산 효율성과 추정 정확도 사이의 최적 균형을 제공한다는 점에서, Kalman Filter 계열 알고리즘은 자원이 제한된 임베디드 시스템의 실시간 상태 추정에 가장 적합한 표준 알고리즘이다. 본 연구에서는 시스템의 선형 근사가 유효한 범위 내에서 KF를 기본 필터로 사용하며, 비선형성이 두드러지는 경우에 대한 EKF 확장은 향후 연구로 남긴다.

2.4 ML/DL 기반 Kalman Filter 연구

KF의 성능을 ML/DL로 개선하려는 연구는 크게 두 방향으로 진행되고 있다. 첫째는 Kalman Gain 자체를 신경망으로 학습하는 접근이고, 둘째는 노이즈 파라미터(Q , R)의 적응에 ML을 활용하는 접근이다.

전자의 대표적 연구로 KalmanNet (Revach et al., 2022) [9]은 RNN 구조를 이용하여 Kalman Gain을 직접 학습하며, 모델 불일치 환경에서 기존 KF 대비 우수한 성능을 보고하였다. 그러나 고성능 GPU 기반의 학습 및 추론을 전제로 하여, MCU 환경에서의 배포 가능성은 고려되지 않았다.

후자에 해당하는 노이즈 파라미터 적응 연구로는, Barros et al. (2025) [10]이 STM32 환경에서 배터리 충전 상태(SoC) 추정에 Adaptive EKF를 적용하였고, RamaNaik & Majumder (2025) [11]가 전기차 SoC 추정에서 잔차 기반 R 조정의 유효성을 실험적으로 검증하였다. 이들은 MCU 기반 적응형 KF의 실현 가능성을 보여주었으나, 적응 방식이 통계적·규칙 기반에 머물러 있다는 한계가 있다.

한편 Zhou et al. (2025) [8]은 변분 베이지안 기반 적응형 필터링을 실내 위치 추정에 적용하였으며, Kim et al. (2024) [12]은 레이더-카메라 융합 기반 3D 객체 인식에서 다중 센서 융합의 최신 동향을 제시하였다.

이상의 선행 연구를 종합하면, KF+ML 연구는 고성능 컴퓨팅 환경을 전제하고, MCU 기반 AKF 연구는 통계적 방법에 의존하는 구조적 공백이 존재한다. 본 연구는 이 공백을 메우기 위해, TinyML 모델을 통해 R 을 실시간 추론하는 구조를 MCU에서 직접 구현한다.

2.5 Edge AI 및 TinyML 기술 동향

TinyML은 마이크로컨트롤러급 장치에서 머신러닝 추론을 실행하는 기술 영역으로, TensorFlow Lite for Microcontrollers (TFLM), STM32Cube.AI, Edge Impulse 등의 프레임워크를 통해 실용화가 진행되고 있다 [4][5].

MCU 환경에서의 추론 효율성에 관하여, Nadalini et al. (2023) [4]은 축소 정밀도(reduced precision) 부동소수점 최적화를 통한 on-device 학습 기법을 제안하여 제한된 자원에서의 DNN 실행 가능성을 확인하였다. MLPerf Tiny Benchmark [13]는 Cortex-M3/M4급 MCU에서의 ML 추론 성능을 체계적으로 벤치마킹하는 표준을 제공하며, MCU 환경 ML 추론의 일반적인 성능 범위와 평가 방법론의 맥락을 제시한다. 특히 Banbury et al. (2021) [17]은

STM32F446RE를 포함한 상용 MCU에서 모델 규모별 추론 지연 시간과 전력 특성을 비교 분석하였으며, 본 연구의 타깃 하드웨어와 직접 대응되는 선행 벤치마크로서 모델 크기 · 양자화 전략의 참고 맥락을 제공한다.

배포 도구 측면에서, STM32Cube.AI [14]는 TensorFlow/Keras/ONNX 모델을 최적화된 C 코드로 변환하여 STM32에 배포하는 도구이며, 본 연구에서 INT8 양자화 모델의 MCU 배포에 활용한다. 그러나 현재 TinyML 연구의 주요 적용 분야는 이미지 분류, 음성 인식, 이상 탐지 등 분류 · 인식 문제에 편중되어 있으며, KF와 같은 상태 추정 알고리즘의 파라미터 적응에 TinyML을 결합하여 MCU에서 실시간 동작을 검증한 연구는 아직 제한적이다. 이는 본 연구가 기여하고자 하는 핵심 영역이다.

2.6 기존 연구의 한계 및 본 연구의 기여

기존 연구들의 한계와 이에 대한 본 연구의 접근 방식 및 기여를 [표 2-3]에 정리한다.

[표 2-3] 기존 연구 한계 및 본 연구의 기여

기존 연구의 한계	본 연구의 접근	연구 기여
KF+ML 연구는 GPU/PC 환경에서 수행	ARM Cortex-M4 기반 MCU(STM32F446RE)에서 TinyML 추론을 실제 임베디드 시스템에 구현	MCU 환경에서 ML 추론을 수행하는 실용적 Edge AI 구현 사례 제시
Adaptive Kalman Filter 연구는 규칙 기반 또는 통계 기반 적응 방법이 중심	ML 기반으로 측정 노이즈 공분산 R 을 추정하는 적응 구조를 MCU에서 구현	동일 MCU 환경에서 통계 기반 (Covariance Matching) 적응과 ML 기반 적응을 공정하게 비교
TinyML 연구는 분류/인식 문제 중심이며 상태 추정 알고리즘과의 결합 연구는 제한적	Kalman Filter 기반 상태 추정 문제에 TinyML 모델을 결합하여 실시간 추론 수행	FPU 탑재 Cortex-M4 MCU에서 TinyML 기반 실시간 추론 가능성 검증
Edge AI 연구는 성능 향상에 집중하며 실제 임베디드 환경에서의 제약 분석은 제한적	실제 센서 노이즈 환경과 다양한 실험 시나리오에서 시스템 성능을 평가	임베디드 Edge AI 시스템의 실용적 한계와 가능성을 동시에 분석

3 장 본론

3.1 시스템 전체 구조

본 연구가 제안하는 시스템은 STM32F446RE MCU 위에서 동작하는 적응형 상태 추정 프레임워크로서, 단일 센서 데이터 스트림으로부터 네 가지 위치 추정값 - Raw 센서값, Fixed KF, CM-AKF, TinyML-AKF - 을 병렬로 산출하여 4.2절의 시나리오에서 공정하게 비교할 수 있도록 설계되었다. 시스템 전체 구조를 [그림 3-1]에 제시한다.


시스템은 크게 (i) 센서 입력 계층, (ii) Feature 추출 계층, (iii) 추정 알고리즘 계층, (iv) 출력 및 제어 계층의 4개 계층으로 구성된다. 센서 입력 계층은 200 Hz로 갱신되는 좌·우 엔코더(FIT0450 $\times$ 2), ~50 Hz로 갱신되는 ToF 센서(VL53L0X), ~20 Hz로 갱신되는 초음파 센서(HC-SR04)로 이루어진다. 각 센서의 갱신 주기 차이를 처리하는 스케줄링은 3.6절에서 상세히 기술한다.

Feature 추출 계층은 센서 측정값과 KF 상태로부터 6개 입력 특징(F1~F6, 표 3-1)을 슬라이딩 윈도우(W = 20) 기반으로 산출하여 TinyML-AKF에 전달한다. HC-SR04는 본 계층의 F4 sensor disagreement 입력으로만 활용되며, KF Update 단계에는 직접 관여하지 않는다. 이 boundary는 본 시스템의 핵심 설계 원칙이며, 3.5.2절과 3.6절에서 반복 명시한다.

추정 알고리즘 계층에서는 동일한 엔코더-기반 운동학 입력과 동일한 VL53L0X 측정값에 대해 세 가지 알고리즘(Fixed KF, CM-AKF, TinyML-AKF)이 병렬로 동작하여 각각의 위치 추정값을 산출한다. 동일 입력에 대한 병렬 동작은 본 연구의 비교 실험에서 알고리즘 간 공정성을 보장하는 핵심 구조이며, 추가로 raw 센서값(VL53L0X 직접 측정)을 baseline으로 함께 기록한다. 알고리즘 계층의 출력에는 각 추정값과 함께 사후 분석에 필요한 내부 상태(kalman_gain, innovation_cov 등)가 포함된다.

데이터 로깅 계층은 50 Hz로 28컬럼 CSV 데이터를 HC-06 Bluetooth UART(115200 baud)를 통해 PC로 무선 전송하며, DMA 더블 버퍼링으로 메인 루프를 블로킹하지 않는다. 이 구현 상세는 3.6절에서 다룬다.

본 시스템은 센서별 개별 동작 검증과 알고리즘의 Python $\leftrightarrow$ C 이식 검증(3.8절)을 완료한 단계이며, 통합 동작 성능과 실 환경 비교 결과는 4장 실험을 통해 평가한다.



[그림 3-1] 제안 시스템 전체 구조

3.2 상태 공간 모델

본 연구는 주차 슬롯 진입 마지막 단계의 직선 접근을 모사하여, 약 500 mm의 짧은 직선 구간을 저속으로 이동하는 2WD 모바일 로봇의 1차원 위치 추정을 대상으로 한다. 4.1.1절에서 기술한 바와 같이 로봇은 해당 구간을 수동으로 굴러 이동시키며, 이동 거리가 짧고 측 방향 외란이 작아 회전 성분은 무시할 수 있다. 따라서 상태 변수는 단일 스칼라 위치 $x(\text{mm})$ 로 정의되며, 본 연구의 모든 알고리즘(Fixed KF, CM-AKF, TinyML-AKF)은 동일한 1D 스칼라 상태 공간 모델 위에서 동작한다.

1. 상태 변수 및 입력

- 상태: $x_k \in \mathbb{R}$ - 시점 k 에서의 트랙 기준 위치 (mm)
- 제어 입력: $u_k \in \mathbb{R}$ - 좌·우 엔코더 속도의 산술 평균 $\frac{v_{left} + v_{right}}{2}$ (mm/s)
- 측정값: $z_k \in \mathbb{R}$ - VL53L0X ToF 센서의 거리 측정값 (mm)

2. 시스템 모델

상태 전이 모델 및 측정 모델은 다음과 같이 정의된다.

$$x_k = F \cdot x_{k-1} + B \cdot u_k + w_k, w_k \sim N(0, Q)$$

$$z_k = H \cdot x_k + v_k, v_k \sim N(0, R)$$

본 연구의 1D 인스턴스에서 각 계수의 구체적 값은 다음과 같다.

- $F = 1$ (상태 전이 계수): 등속 가정 하에서 직전 위치를 그대로 유지
- $B = \Delta t = 0.005$ s (제어 입력 계수): 200 Hz 메인 루프의 샘플링 주기
- $H = 1$ (측정 모델 계수): 위치를 직접 측정
- $Q = 1.0$ mm² (프로세스 노이즈 분산, 고정): 1.2절에서 기술한 바와 같이 본 연구는 R 적응에 범위를 한정하므로 Q 는 고정값으로 운용
- $R_0 = 400$ mm² (측정 노이즈 분산 초기값, E0 시뮬레이션용 잠정값): VL53L0X 데이터시트(ST DocID029104, Section 2.3)의 표준 조건 $\sigma \approx \pm 20$ mm로부터 산출. E1-E5 실험에는 4.1.3절의 500 mm 캘리브레이션으로 확인한 실측 R_0 를 적용

본 연구는 시뮬레이션(E0) $R_0 = 400$ mm² 와 실측(E1-E5) $R_0 = 24$ mm² 의 두 값을 분리 운용한다. E0는 데이터시트 보수값 기반의 이상적 일관성 검증용이며, E1-E5는 운용 환경(500 mm, 흰 우드락) 실측 캘리브레이션 기반이다.

3. 알고리즘별 R의 처리 방식

세 가지 알고리즘은 위 모델을 공유하되, R의 처리 방식만이 차별점이다.

(1) Fixed KF (3.3절): $R = R_0 = 400$ mm² 로 고정

(2) CM-AKF (3.4절): $R(k)$ 를 매 스텝 Covariance Matching 공식으로 갱신, 클램프 [1.0, 10000.0] mm²

(3) TinyML-AKF (3.5절): $R(k)$ 를 매 스텝 학습된 신경망의 추론 결과로 갱신, 동일 클램프 적용

이러한 일관된 모델 위에서 R의 처리 방식만 다르게 함으로써, 본 연구의 비교 실험은 적응 메커니즘 자체의 효과를 분리하여 평가할 수 있도록 설계되었다.

Q와 R 초기값(R_0)에 대한 NIS 기반 일관성 검증은 4.3절의 평가 지표에 따라 $\chi^2(df = 1)$ 95% 양측 신뢰구간 내 비율로 정량화되며, 합성 데이터 시뮬레이션(E0)에서 95.5 %의 신뢰구간 통과율로 본 모델 설정의 적절성을 사전 확인하였다 (4.2절 참조).

3.3 Fixed KF (Baseline 1)

Fixed KF는 측정 노이즈 분산 R 을 시간에 무관한 상수로 운용하는 표준 칼만 필터로서, 본 연구의 첫 번째 baseline이다. 3.2절에서 정의한 1D 스칼라 모델 위에서, 각 알고리즘 간 비교의 기준점을 제공한다.

1. 알고리즘 정의

매 메인 루프(200 Hz)에서 다음 두 단계가 순차적으로 수행된다.

(1) Prediction (매 스텝):

- $\hat{x}_{k|k-1} = \hat{x}_{k-1|k-1} + \Delta t \cdot u_k$
- $P_{k|k-1} = P_{k-1|k-1} + Q$

(2) Update (VL53L0X 새 데이터 도달 시, ~50 Hz):

- $K_k = \frac{P_{k|k-1}}{P_{k|k-1} + R}$
- $\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \cdot (z_k - \hat{x}_{k|k-1})$
- $P_{k|k} = (1 - K_k) \cdot P_{k|k-1}$

여기서 $R = R_0$ 로 고정하며, $Q = 1.0 \text{ mm}^2$ 또한 고정이다 (3.2절). R_0 는 4.1.3절의 정적 캘리브레이션으로 확인한 실측값을 사용하며, E0 시뮬레이션 단계에서는 데이터시트 기반 잠정 초기값 400 mm^2 를 적용한다(3.2절). VL53L0X로부터 새 측정값이 도달하지 않은 루프에서는 Update 단계를 건너뛰고 Prediction만 수행한다 (3.6절 참조).

2. 임베디드 구현 디테일

본 알고리즘은 STM32F446RE의 Cortex-M4 FPU를 활용하여 32비트 단정밀도 부동소수점(float32) 연산으로 구현되며, 1D 스칼라 모델이므로 행렬 연산이 불필요하여 한 스텝당 산술 연산 수가 10회 미만이다. 수치 안정성 확보를 위해 P 값에 바닥($P_{\min} = 10^{-6} \text{ mm}^2$) 보호를 적용하여, 부동소수점 누적 오차로 P 가 0에 근접하는 경우 필터 발산을 방지한다.

3. Python ↔ C 등가성 검증

본 구현은 Python 시뮬레이션과 동일 입력에 대해 매 스텝 출력을 비교하여 검증되었다. 검증 결과 $\hat{x}$, K , r 등 전 필드에서 절대 오차 1×10^{-3} 이내를 충족하였으며, 상세 검증 방법론은 3.8절에 기술한다.

4. Baseline으로서의 위상

Fixed KF는 표면 반사율 변화 등 동작 환경의 노이즈 특성 변동에 적응하지 못하는 한계가 있다. 본 baseline은 (i) E0 시뮬레이션에서 KF 자체의 정상 동작을 검증하고, (ii) 적응형 알고리즘(CM-AKF, TinyML-AKF) 대비 적응이 가져오는 개선 폭을 정량화하기 위한 기준점으로서 기능한다.

3.4 CM-AKF (Baseline 2)

CM-AKF (Covariance Matching Adaptive Kalman Filter)는 본 연구의 두 번째 baseline으로서, 2.2.3절에서 분류한 Innovation-based / Covariance Matching 계열 [2]의 표준 적응 기법이다. 본 절에서는 이를 본 연구의 1D 인스턴스에 적용한 구체적 구현을 기술한다.

1. 알고리즘 정의

CM-AKF는 Fixed KF의 Prediction-Update 구조에 R 적응 단계를 추가한 형태이다. 매 메인 루프에서 다음 순서로 수행된다.

(1) 잔차 갱신: KF Update 직전, 현재 측정값에 대한 예측 잔차 $r_k = z_k - \hat{x}_{k|k-1}$ 를 계산하여 슬라이딩 윈도우 버퍼에 추가

(2) R 적응: 윈도우 버퍼가 충전된 상태($k \geq W$)에서 다음 공식으로 R 을 갱신

$$\circ R_k = (1/W) \sum_{i=k-W+1}^k r_i^2 - P_{k|k-1}$$

(3) R 클램핑: 수치 안정성 확보를 위해 R_k 를 $[R_{min}, R_{max}] = [1.0, 10000.0] \text{ mm}^2$ 범위로 제한

(4) Update: 갱신된 R_k 를 사용하여 Fixed KF와 동일한 Update 단계 수행

윈도우 미충전 구간($k < W$)에서는 $R_k = R_0 = 400 \text{ mm}^2$ 의 고정값을 사용한다 (E0: 400 mm^2 , E1-E5: 24 mm^2 , 3.2절 참조). 본 연구는 윈도우 크기를 $W = 20$ (100 ms)으로 채택하였으며, 그 근거는 1.2절 및 4.2절 E0 분석에 기술하였다.

2. 임베디드 구현 디테일

잔차 슬라이딩 윈도우는 길이 W 의 순환 버퍼(circular buffer)로 구현되며, 잔차 제곱합과 잔차 합을 누적 변수로 유지하여 매 스텝 $O(1)$ 시간에 윈도우 평균을 갱신한다. 새 잔차 r_k 가 들어오면 가장 오래된 r_{k-W} 를 제거하고 누적합에 더하는 방식으로, 200 Hz 루프 안에서 추가 연산 부담을 최소화하였다. R 클램핑은 $\text{fmaxf}(\text{fminf}(R_k, R_{\max}), R_{\min})$ 의 두 비교로 구현되며, 음수 R 발생(이론적으로 표본 분산이 $P_{k|k-1}$ 보다 작을 때 가능) 시 $R_{\min}$ 으로 강제하여 필터 발산을 방지한다.

3. Python ↔ C 등가성 검증

본 구현은 Python 시뮬레이션과 동일 입력에 대해 매 스텝 출력을 비교하여 검증되었다. 검증 결과 $\hat{x}$, K , r 전 필드에서 절대 오차 1×10^{-3} 이내를 충족하였다. 다만 innovation covariance $S = P_{k|k-1} + R_k$ 는 슬라이딩 윈도우 내 잔차 제곱합의 float32 누적 특성으로 최대 0.005 mm^2 의 차이가 관찰되었으나, S 의 절대값($400 \sim 800 \text{ mm}^2$) 대비 상대 오차 0.001 % 미만으로 실용적 영향이 없다 (3.8절 참조).

4. Baseline으로서의 위상과 구조적 한계

CM-AKF는 임의의 임계값(threshold) 설정에 의존하지 않고 잔차 통계로부터 R 을 이론적으로 추정하므로, 규칙 기반 적응의 상한(upper bound) 성능을 대표하는 baseline이다 (2.2.3절). 그러나 잔차 제곱 평균이라는 단일 통계에만 의존하기 때문에, 잔차가 일관되게 큰 상황(예: 센서 고장으로 측정값이 고정되는 경우)에서는 적응 메커니즘이 $R \rightarrow K \rightarrow P \rightarrow R$ 로 이어지는 순환 고리에 갇히는 구조적 문제가 발생한다. 구체적으로, 큰 잔차에 의해 R 이 증가하면 칼만 게인 $K = P^- / (P^- + R)$ 이 감소하여 센서 측정을 불신하게 되고, 이로 인해 측정에 의한 오차 공분산 보정($P^+ = (1 - K) \cdot P^-$)이 약해져 예측 공분산 P 가 지속적으로 누적된다. 누적된 P 는 다시 K 를 끌어올려, R 을 증가시켜 센서를 불신하려던 본래 의도와 반대로 칼만 게인이 회복되는 결과를 낳는다.

즉 CM-AKF는 R 을 키워도 P 누적을 통해 그 효과가 상쇄되므로, 신뢰할 수 없는 센서를 안정적으로 배제하지 못한다. 본 연구의 합성 데이터 사전 검증 결과, stuck sensor 시나리오에서 CM-AKF의 RMSE가 Fixed KF 대비 약 23 % 열화됨을 확인하였다 (229 mm vs 186 mm, 2.2.3절 참조). 이 구조적 한계는 본 연구가 다변량 feature 기반 TinyML-AKF (3.5절)를 도입한 핵심 동기이며, 실 환경에서의 재현 여부는 4.2절 E3 시나리오에서 정량적으로 검증한다.

3.5 TinyML-AKF

본 절에서는 TinyML 모델을 통해 측정 노이즈 공분산 R 을 실시간으로 추정하는 적응형 필터 구조(TinyML-AKF)를 기술한다. 3.5.1절에서 알고리즘 선택 근거를, 3.5.2 ~ 3.5.3절에서 입력 feature와 모델 구조를, 3.5.4절에서 학습 라벨 생성 방법을, 3.5.5 ~ 3.5.6절에서 학습 파이프라인 및 INT8 양자화를 각각 다룬다. 본 연구에서 제안하는 모델은 합성 데이터를 이용한 end-to-end 파이프라인 검증 후, 실 환경 데이터(E1-E3) 수집 후 6-feature 모델로 재학습하여 MCU에 배포한다.

3.5.1 알고리즘 선택 근거

한편, pseudo-label 생성에 사용된 Covariance Matching 공식을 실시간 제어 루프에서 직접 적용하여 R 을 갱신하는 것도 이론적으로 가능하다. 그러나 본 연구에서 TinyML 기반 접근을 채택한 데에는 두 가지 구조적 근거가 있다.

첫째, Covariance Matching은 잔차 제곱 평균이라는 단일 통계에만 의존하여 R 을 추정하는 반면, TinyML 모델은 잔차 통계 외에도 sensor disagreement, measurement rate, signal rate를 동시에 고려한다. 특히 signal rate는 표면 반사율 변화 시 잔차가 실제로 증가하기 전에 먼저 변화하는 선행 지표(leading indicator)로서, R 의 선제적 조정을 가능하게 한다.

둘째, Covariance Matching 공식에서 $R(k)$ 는 칼만 게인 $K(k)$ 와 예측 공분산 $P_{k|k-1}$ 을 거쳐 다시 이전 스텝의 R 에 의존하므로, $R \rightarrow K \rightarrow P \rightarrow R$ 로 이어지는 순환 의존성이 존재하며, 실시간 적용 시 추정이 불안정해질 수 있다. TinyML 모델은 P 를 입력으로 사용하지 않고 센서 feature만으로 R 을 추론하므로 이 순환 의존성을 구조적으로 회피한다. 다만, Covariance Matching 기반 pseudo-label은 완전한 ground truth가 아니며, 윈도우 크기와 초기 고정 R 설정에 따른 추정 노이즈를 포함할 수 있다. 본 연구에서는 이러한 한계가 TinyML 모델의 실제 성능에 미치는 영향을 포함하여, 위 논거의 유효성을 실험적으로 검증한다.

3.5.2 Feature 설계

TinyML 모델의 입력 feature는 ToF 센서 신뢰도와 직간접적으로 연관된 6개 특징으로 구성하며, 1.2절에서 개괄한 6 feature를 본 절에서 정량적 정의와 함께 기술한다. 각 feature는 200 Hz 메인 루프 내에서 $W = 20$ (100 ms) 슬라이딩 윈도우 기반으로 산출하며, KF Update 단계 직전에 업데이트되어 추론 입력으로 전달된다. HC-SR04는 본 모델의 보조 feature (F4 sensor disagreement) 입력으로만 사용되며 KF Update에는 직접 관여하지 않는다. 6개 feature의 정의와 산출 시점은 [표 3-1]에 정리하였다.

[표 3-1] Feature 정의

ID	이름	정의(수식)	물리적 의미	산출 시점
F1	Residual	$r(k) = z(k) - \hat{x}_{k k-1}$	예측값과 측정값의 순간 불일치	KF Update 직전, 매 루프
F2	Residual Variance	$Var[r] \text{ over } W = 20$	최근 100 ms 동안의 측정 노이즈 강도	$O(1)$ 점진적 업데이트
F3	Residual Mean	$Mean[r] \text{ over } W = 20$	측정 바이어스 또는 예측 모델 오차의 누적 경향	$O(1)$ 점진적 업데이트
F4	Sensor Disagreement	$ z_{VL53L0X} - z_{HC-SR04} $	주센서 · 보조센서 간 일치도; 한쪽 센서 이상 감지	HC-SR04 갱신 (20 Hz) 시점만 새로 계산, 그 외 hold
F5	Measurement Rate	윈도우 내 range_status==0 비율	정상 측정의 비율; 신호 손실 정도 정량화	윈도우 내 카운팅
F6	Signal Rate	VL53L0X 반사 신호 세기 (MCPS 단위, 16.16 fixed- point → float32 변환)	표면 반사율의 직접 지표; 잔차 변화의 선행 지표	VL53L0X 갱신 (50 Hz) 시점만 새로 갱신, 그 외 hold

6개 feature는 ToF 센서 신뢰도에 영향을 미치는 세 가지 정보 채널 - 잔차 통계 (F1~F3), 센서 간 교차 검증 (F4), 센서 자체 신호 품질 (F5, F6) - 을 균등하게 포괄하도록 설계되었다. 특히 F6 signal rate는 표면 반사율이 변화할 때 잔차 통계가 반응하기 이전에 먼저 변화하는 선행 지표(leading indicator)로서, R의 선제적 조정을 가능하게 한다. 이 가설의 유효성은 5장 RQ3 분석에서 E3 차단 시나리오의 시계열 선후 관계 분석(그림 5-2)으로 검증한다.

F5는 본 학습 환경(E1 · E2 · E3, E5)에서는 윈도우 내 status==0 비율이 전 구간 1.0이어서 사실상 상수 입력으로 작용한다 (5장). 본 연구는 F5를 입력 채널에서 제거하지 않고 더 극단적 신호 손실 환경(예: 센서 물리적 가림)에 대비한 예비 채널(reserve channel)로 유지한다.

3.5.3 모델 구조

본 연구의 TinyML 모델은 6차원 feature 벡터를 입력으로 받아 측정 노이즈 공분산 R 을 단일 스칼라로 출력하는 Multi-Layer Perceptron (MLP) 회귀 모델로 설계되었다. 입력층 6 노드, 첫 번째 은닉층 16 노드, 두 번째 은닉층 8 노드, 출력층 1 노드의 4계층 구조로, 총 학습 파라미터 수는 257개이다. MCU의 자원 제약을 고려하여 최소 규모로 설계되었으며, INT8 양자화 후 가중치 메모리는 약 0.3 KB로 STM32F446RE의 Flash 대비 0.06% 미만을 차지한다 (3.5.6절 참조).

[표 3-2] 모델 구조

계층	입력 차원	출력 차원	활성화 함수	파라미터 수
입력층	6	6	-	0
Dense 1	6	16	ReLU	$6 \times 16 + 16 = 112$
Dense 2	16	8	ReLU	$16 \times 8 + 8 = 136$
출력층	8	1	Linear (학습 시 loglp 공간)	$8 + 1 = 9$
합계	-	-	-	257

정규화 상수는 4.4절 데이터 분할에 따라 TinyML 학습 데이터의 부분집합인 E1 1차 측정 Run 1-3에서 fit하며, 학습 데이터 전체가 아닌 baseline에서만 fit하는 이유는 E2 반사율 변화나 E3 동적 outlier 통계가 정규화 기준에 포함되면 모델이 변동·outlier 입력을 정상값으로 normalize하여 변별력을 잃기 때문이다. 산출된 정규화 상수는 다음과 같다: F1 (mean=0.1142, std=4.5925), F2 (21.1487, 11.7192), F3 (0.0327, 0.7664), F4 (23.4318, 6.4479), F5 (1.0000, 1.0000 [std_safe]), F6 (8.6278, 6.7548). INT8 양자화는 stedgeai CLI를 통해 수행하였으며, 입력 텐서 스케일 0.913747 / zero point 31, 출력 텐서 스케일 0.038761 / zero point -128로 결정되었다.

출력층 활성화 함수는 Linear로 설정하고, 학습 시 label을 $\text{loglp}(R) = \ln(1+R)$ 공간으로 변환하여 사용한다. 이러한 설계는 R 의 분포 특성에 기인한다. 본 연구의 R 적응 범위는 CM-AKF와 동일한 $[1.0, 10000.0] \text{ mm}^2$ 이며, 이 구간 내에서 R 은 heavy-tailed 분포를 가진다(E1 정상 주행 시 데이터시트 기반 가정값 약 400 mm^2 , E3 stuck sensor 또는 E2 저반사 표면 시 $R_{\max} \approx 10,000 \text{ mm}^2$ 로 약 25배 차이).

원 R 공간에서 직접 학습할 경우 큰 R 값을 가진 샘플이 손실 함수를 지배하여 정상 구간의 학습이 악화되며, INT8 양자화 시에도 출력 텐서의 scale factor가 큰 동적 범위를 표현하기 어렵다. log1p 변환을 적용하면 label 범위가 [0.69, 9.21]로 압축되어 위 두 문제가 동시에 해결된다.

추론 단계에서는 모델 출력 $\hat{y}$ 에 $\text{expm1}(\hat{y}) = e^{\hat{y}} - 1$ 을 적용하여 R 값을 복원하고, CM-AKF와 동일한 범위 [1.0, 10000.0]으로 clamp하여 R 의 양수 제약과 수치 안정성을 함께 보장한다. 즉, R 의 양수 제약은 출력층 활성화 함수가 아닌 추론 후처리 단계의 clamping으로 강제된다.

3.5.4 Pseudo-label 생성

Pseudo-label 생성은 Covariance Matching 기반 방식으로 수행한다. Kalman Filter 이론에 따르면 innovation(잔차) $r(k)$ 의 공분산은

$$S(k) = HP_{k|k-1}H^T + R(k)$$

를 만족한다.

이를 이용하여 최근 W_{label} 스택의 잔차를 기반으로 공분산을 추정하고, 이를 통해 $R(k)$ 를 계산한다. 잔차 공분산은 최근 윈도우 구간의 $r(i)$ 에 대해 평균 제곱값 형태로 계산한다.

이때 일반적인 형태의 $R(k)$ 는

$$\text{추정된잔차공분산} - HP_{k|k-1}H^T$$

로 표현된다.

본 연구에서는 스칼라 측정 모델에서 $H = 1$ 이므로 위 식을 단순화하고, $R(k)$ 를

$$\text{최근 } W_{label} \text{ 구간의 } r(i)^2 \text{ 평균} - P_{k|k-1}$$

형태로 계산한다.

또한 label 안정성을 위해 $W_{label} = 20$ 의 윈도우를 사용하여 pseudo-label을 생성한다.

본 pseudo-label은 펌웨어의 CM-AKF update 블록에서 매 step 계산되어 CSV의 cm_R 컬럼에 [1.0, 10000.0] mm² clamp 후 저장되며, 학습 스크립트는 해당 컬럼에 log1p 변환만 추가 적용한다. 실측 R 분포는 시나리오에 따라 크게 다르다 - E1 baseline에서는 cm_R 범위가 [1.46, 71.03] mm² (1차 5 run 통합 평균 16.87 mm², W=20 미충전 구간 제외) 범위로 3.5.3절에서 가정한 'E1 정상 $R \approx 400$ mm²'보다 약 25배 좁으며, E3 동적 차단 시나리오에서는 R 이 10,000 mm² clamp 한계에 도달하는 stuck sensor 패턴이 재현된다.

3.5.5 학습 파이프라인 설계

TinyML 모델 학습은 오프라인 환경(Python/TensorFlow 2.21)에서 수행하며, 학습된 float32 모델을 TFLite Converter로 INT8 양자화한 후 ST Edge AI Core 4.0 (stedgeai CLI 우회 경로, LL ATON 런타임)을 통해 C 코드로 변환하여 MCU에 배포한다. STM32Cube.AI GUI는 본 연구 환경에서 안정적 동작에 문제가 있어 CLI 경로를 채택하였다. 학습 데이터는 4.4절의 데이터 분할 전략에 따라 E1-E3의 Run 1-3을 사용하고, 정규화 파라미터는 E1 학습 데이터로부터 산출하여 펌웨어 상수로 하드코딩한다. 본 연구는 합성 데이터(synth_E1~E5)를 이용해 파이프라인 end-to-end 동작을 사전 검증하며, 실 환경 데이터 수집 후 동일 파이프라인으로 6-feature 모델을 재학습한다.

학습 하이퍼파라미터는 [표 3-3]과 같이 설정하였다. 본 표의 값은 합성 데이터(synth_E1-E5)를 이용한 사전 검증 단계에서 결정한 설정이며, 실 환경 데이터(E1-E3) 수집 후 동일 값으로 재학습한다. 다만 입력 feature 수는 합성 데이터에서 3-feature(잔차 통계만)로, 실 데이터에서 6-feature로 차이가 있다.

[표 3-3] 학습 하이퍼파라미터

분류	항목	값	근거/비고
모델 입출력	입력 차원	6 (메인 모델) / 3 (ablation 모델)	표 3-1 참조
	출력 차원	1 (스칼라 R)	log1p 변환된 공간에서 학습
	출력 변환	log1p / expm1	양자화 안정성 확보 (3.5.3 참조)
최적화	Optimizer	Adam	적응적 학습률, 소형 회귀 모델에서 표준 선택
	초기 학습률	3×10^{-3}	-
	손실 함수	MSE (log1p 공간)	원 R 공간에서는 큰 R 샘플이 손실을 지배하여 정상 구간 학습이 약화됨

학습 제어	Batch size	32	-
	최대 epoch	500	조기 종료로 자동 중단
	Early stopping	patience = 20, monitor = val_loss	검증 손실 20 epoch 무개선 시 중단
	Best weight 복원	활성화	val_loss 최소 시점의 가중치를 최종 모델로 사용
데이터 처리	Train/Val 분할	8 : 2 (run 단위)	4.4절 데이터 분할 전략 참조
	정규화	feature별 Standard normalization (mean, std)	E1 Run 1-3에서 fit, 동일 변환을 E1 · E2 · E3 학습/평가 데이터 전체에 적용. F5는 std=0이므로 std_safe=1.0으로 매핑하여 모델 입력이 상수 0이 되도록 처리. transform 단계에서 정규화 후 범위 밖 값은 clip하지 않고 OOD 신호로 보존.
	Label 클램핑	[1.0, 10000.0] mm ² 후 log1p 적용	CM-AKF R 클램핑 범위와 일치 (3.4절)
양자화	양자화 방식	Post-training INT8	TFLite Converter
	대표 데이터셋	학습 세트의 임의 200 샘플	양자화 calibration용
	목표 정확도	사전 검증 목표 float32 대비 R 추정 $\pm 5\%$, 실측 결과는 표 4-10 참조	4.4절 검증 기준

Optimizer로는 적응적 학습률을 제공하는 Adam을 사용하며, 초기 학습률 3×10^{-3} 은 합성 데이터에서 232 epoch 시점에 best validation loss를 달성한 설정이다. Early stopping은 과적합 방지와 학습 시간 단축 목적으로 patience = 20을 적용하였으며, 사전 검증에서는 252 epoch 시점에 자동 종료되었다. Label은 R 의 heavy-tailed 분포 특성으로 인한 양자화 불안정

문제(3.5.3절 참조)를 피하기 위해 $\log_{1p}$ 공간으로 변환한 뒤 학습한다. 정규화 파라미터(feature별 평균 · 표준편차)는 학습 데이터 통계에서 산출하여 MCU 펌웨어 헤더에 상수로 하드코딩하며, 추론 시점에 동일 변환을 적용한다.

3.5.6 INT8 양자화

MCU의 메모리 제약과 정수 연산 성능을 고려하여, 학습된 float32 모델에 대해 Post-training INT8 양자화를 적용한다. 양자화는 TensorFlow Lite Converter의 `optimizations = [tf.lite.Optimize.DEFAULT]` 옵션과 representative dataset 기반 calibration을 통해 수행하며, 가중치와 활성화 텐서 모두 8비트 정수로 변환된다. Calibration용 대표 데이터셋으로는 학습 세트에서 임의 추출한 200개 샘플을 사용하여 텐서별 양자화 스케일(scale factor)과 영점(zero point)을 결정한다. 본 연구에서 학습 label을 $\log_{1p}(R)$ 공간으로 변환한 이유는 3.5.3절에 기술하였다.

설계된 6-feature 정식 모델의 총 학습 파라미터 수는 257개로, INT8 양자화 적용 시 약 0.3 KB 수준의 가중치 메모리만 요구되며 STM32F446RE의 Flash 자원(512 KB) 대비 약 0.06 %를 차지한다. 양자화 후 모델 파일 크기는 약 3.16 KB이다.

한편 본 절의 사전 검증은 실 환경 데이터 수집 이전 단계에서 합성 데이터로 수행되었으므로, 입력이 잔차 통계 3개(F1~F3)로 제한된 3-feature 축소 모델(파라미터 209개)을 대상으로 한다. 합성 데이터(synth_E1-E5) 기준 이 축소 모델의 float32 test MAE는 평균 R 1016.6 mm² 대비 10.4 % (106.35 mm²), INT8 양자화 후 16.4 % (166.85 mm²)로 측정되어, 양자화에 따른 추가 오차는 약 6 %p 수준이었다.

이 사전 검증은 합성 데이터 분포 하에서 학습 파이프라인이 end-to-end로 정상 동작하고 INT8 양자화가 가중치 손실 없이 적용 가능함을 확인한 단계이며, 실 환경 데이터에서의 정확도 보장은 4.4절 검증 기준(± 5 %)에 따라 별도로 평가한다.

다만 $\log_{1p}$ 공간 복원(expm1) 시 $R \approx 0$ 근처 샘플에서 최대 상대 오차 958%가 관찰되었다. 이는 log-space에서 미세한 오차가 원 공간에서는 0에 가까운 분모로 인해 큰 상대 오차로 환원되는 수학적 특성과, 합성 데이터에 R 이 1.0 ($R_{\text{MIN clamp}}$ 하한) 근처에 몰린 샘플이 다수 포함된 분포 특성이 겹친 결과이다. 실 데이터(E1-E3) 수집 후 6-feature 정식 모델로 재학습하여 ± 5 % 이내의 양자화 정확도를 재검증한다(4.4절 참조).

MCU 배포는 ST Edge AI Core 4.0의 stedgeai CLI를 통해 수행한다. INT8 양자화된 .tflite 파일을 stedgeai CLI에 입력하면 STM32F4 시리즈에 최적화된 C 코드(network.c,

network.h, weight 배열)가 자동 생성되며, 이를 펌웨어 프로젝트에 통합하여 200 Hz 메인 루프 안에서 호출한다. 추론 시간 측정은 4.3절에서 정의한 DWT 사이클 카운터를 이용한다.

3.6 데이터 흐름과 처리 파이프라인

KF 예측-갱신 루프는 TIM6 타이머 인터럽트에 의해 200 Hz(5 ms 주기)로 구동된다. 그러나 각 센서의 물리적 갱신 속도 상한이 다르므로, 전 센서를 동일 주기로 읽는 것은 불가능하다. 이에 따라 [표 3-4]와 같이 센서별 갱신 주기를 차등 적용하되, KF Prediction 단계는 매 루프 엔코더 기반으로 수행하고, KF Update 단계는 VL53L0X에 새 데이터가 준비된 경우에만 실행한다.

[표 3-4] 200 Hz KF 루프 내 센서 스케줄링

센서	루프 내 갱신 주기	KF 역할 및 처리 방식
FIT0450 엔코더 ×2 (좌/우)	매 루프 (200 Hz)	KF Prediction 전용; TIM 카운터 직접 읽기 (~1 μ s), 매 스텝 구동
VL53L0X (ToF)	4루프마다 (~50 Hz)	KF Update 전용; GetMeasurementDataReady() 폴링 후 I^2C 읽기(~200 μ s), Continuous 모드
HC-SR04 (초음파)	10루프마다 (~20 Hz)	TinyML 입력 특징 F5(sensor_disagree) 계산에 사용; TIM3 Input Capture 인터럽트 비동기 처리, 폴링 금지

HC-SR04의 Echo 신호는 최대 왕복 시간이 약 23 ms에 달하므로, 폴링(polling) 방식으로 대기할 경우 루프 4-5회를 블로킹한다. 이를 방지하기 위하여 TIM3 CH1 Input Capture 인터럽트 방식으로 처리하며, 메인 루프는 echo_ready 플래그만 확인한다. VL53L0X는 Continuous Ranging 모드로 동작시켜 20 ms 주기로 자동 측정을 수행하게 하고, 매 루프에서 GetMeasurementDataReady()를 폴링하여 새 데이터 존재 여부를 확인한다. 루프 실행 시간은 DWT(Data Watchpoint and Trace) 사이클 카운터로 프로파일링하며, 4.5 ms 초과 시 오버런(overflow)으로 계수한다.

본 실험은 로봇을 손으로 굴러 이동시키므로, USB 케이블을 연결할 경우 케이블의 장력과 무게가 굴림 동작과 등속성을 방해한다. 이를 피하기 위하여 HC-06 Bluetooth UART 모듈(115200 baud)을 STM32의 USART6(PC6 TX)에 연결하고, DMA 더블 버퍼링을 통해 CPU 블로킹 없이 무선 전송한다. UART 대역폭 분석(115200 baud / 10 bits = 11,520 B/s)에 의거하여 200 Hz KF 루프 중 4루프에 1회(50 Hz) 로깅하며, 행당 약 220-320 B의 28컬럼 CSV 포맷으로 전송한다. CSV는 (i) 공통 12컬럼 (seq, timestamp_ms, tof_distance_mm, tof_signal_rate,

tof_range_status, us_distance_mm, encoder_distance_mm, encoder_speed_mms, sensor_disagree, tof_meas_rate, gt_distance_mm, scenario_id) , (ii) Fixed KF 6컬럼 (fixed_estimate_mm, fixed_residual, fixed_residual_var, fixed_residual_mean, fixed_kalman_gain, fixed_innovation_cov), (iii) CM-AKF 7컬럼 (cm_estimate_mm, cm_residual, cm_residual_var, cm_residual_mean, cm_kalman_gain, cm_innovation_cov, cm_R), (iv) TinyML-AKF 3컬럼 (tinyml_estimate_mm, tinyml_R, tinyml_infer_us)으로 구성된다. 세 알고리즘이 동일한 ToF/encoder 입력을 공유하면서 동일 MCU에서 병렬 동작하므로, 동일 측정 frame에서 세 추정값을 직접 비교할 수 있다.

kalman_gain은 사후 NIS 계산 및 P 역산에, innovation_cov ($S = P^- + R$)는 NIS 직접 산출에 각각 사용된다. PC 측에서는 pyserial 기반 수신 스크립트가 가상 COM 포트를 통해 데이터를 수집·저장한다. 특히 Kalman gain(K_k)은 적응형 시나리오(E1-E5)에서 매 스텝 변동하므로, 사후 NIS 계산 및 $P_{k|k-1}$ 역산을 위해 kalman_gain 컬럼을 CSV에 포함한다.

3.7 임베디드 안정성 설계

본 연구의 시스템은 200 Hz 메인 루프 안에서 다수의 비동기 이벤트(I²C 통신, 타이머 인터럽트, DMA 전송, TinyML 추론)를 처리하며, 일부 이벤트의 일시적 이상이 전체 제어 루프의 정지 또는 발산으로 이어지지 않도록 다층적 안전 메커니즘을 설계하였다. 본 절에서는 (i) 알고리즘 수준 fallback, (ii) 통신 수준 에러 핸들링, (iii) 시스템 수준 watchdog, (iv) 전원 분리의 네 가지 메커니즘을 기술한다.

1. 알고리즘 수준: TinyML → CM-AKF Fallback

TinyML 추론 결과가 비정상값(NaN, Inf, 또는 클램프 범위를 크게 벗어난 음수)으로 산출되는 경우, 해당 루프에서는 CM-AKF의 R 추정값($R_k = \text{mean}(r^2) - P_{k|k-1}$)을 즉시 대체값으로 사용한다. 이 fallback은 매 추론 직후 단일 비교 분기로 구현되며, 추가 연산 비용은 무시 가능한 수준이다. 본 메커니즘은 INT8 양자화 모델의 극단 입력에 대한 수치적 안정성을 알고리즘 수준에서 보장하는 마지막 방어선이다.

2. 통신 수준: I²C 에러 핸들링

VL53L0X와의 I²C 통신은 전자기 간섭이나 일시적 신호 무결성 저하로 인해 NACK 또는 timeout 오류를 발생시킬 수 있다. 이러한 경우 본 시스템은 다음 정책을 따른다. 첫째, HAL_I2C_ErrorCallback 안에서 I²C 페리페럴을 리셋하고 VL53L0X를 재초기화한다. 둘째, 재초기화 진행 중인 루프에서는 KF Update를 건너뛰고 Prediction만 수행하여 추정의 연속성을

유지한다. 이는 3.6절에서 기술한 "VL53L0X 새 데이터 도달 시에만 Update" 정책과 동일한 동작 모드로 자연스럽게 흡수된다. 셋째, I²C 모든 호출에 timeout(기본 100 ms)을 설정하여 응답 지연이 메인 루프를 무한 블로킹하지 않도록 한다.

3. 시스템 수준: Independent Watchdog (IWDG)

메인 루프 자체의 정지(예: 의도치 않은 무한 루프, 인터럽트 핸들러 데드락)에 대비하여 STM32 내장 Independent Watchdog을 활성화한다. 설정값은 prescaler 32, reload 2000으로, LSI 클럭(~32 kHz) 기준 약 2초의 타임아웃을 갖는다. 메인 루프는 매 반복(5 ms)마다 IWDG_KR 레지스터에 refresh 명령을 기록하여 watchdog을 재설정하며, 2초 이상 refresh가 누락되면 MCU가 자동 리셋된다. 200 Hz 루프 기준 정상 동작 시 5 ms 단위로 refresh가 발생하므로, 2초 임계는 약 400회의 루프 누락이 있어야 도달하는 충분히 안전한 마진이다.

4. 전원 분리

무선 송신 모듈(HC-06)은 6 V 출력 배터리팩을 통해 메인 전원 계통과 분리하여 공급한다. 이는 무선 송신 부하의 순시 전류 변동이 MCU·센서 전원 라인에 결합되어 ADC·I²C 통신에 노이즈로 유입되는 경로를 차단하기 위한 설계이다.

위 네 가지 메커니즘은 각각 다른 계층의 이상에 대응하며, 정상 동작 시에는 200 Hz 메인 루프의 시간 예산(5 ms)에 거의 영향을 주지 않는다. 본 안전성 설계는 발표 시점에 개별 검증된 상태이며, 통합 동작에서의 실효성은 4.2절 E4 (30분 장기 안정성) 시나리오에서 평가한다.

3.8 구현 검증 방법론

본 연구가 사용하는 세 알고리즘(Fixed KF, CM-AKF, TinyML-AKF)은 모두 Python 환경에서 사전 검증된 후 STM32 환경의 C 코드로 이식되었다. 두 환경 사이의 출력의 동일함을 확인하지 않으면, 4장에서 보고하는 임베디드 실험 결과의 차이가 알고리즘 자체의 차이인지 이식 과정에서 발생한 구현 오류인지 분리할 수 없다. 본 절에서는 이를 분리하기 위해 수행한 Python ↔ C 등가성 검증의 프로토콜과 결과를 기술한다. 검증은 두 단계로 수행하였다. 1차 검증(3.8.1절)은 PC 환경에서 동기 입력에 대해 순수 알고리즘 코드를 비교하는 단계이며, 2차 검증(3.8.2절)은 센서·로깅이 통합된 실제 펌웨어를 대상으로 한 재검증이다.

3.8.1 1차 검증 – 알고리즘 단계 등가성

본 1차 검증은 PC 환경에서 200 Hz 동기 입력에 대해 순수 알고리즘 코드를 비교하는 단계로, 입력 정밀도와 행 정렬이 통제된 조건에서 수행된다. 검증은 다음 4단계로 수행된다.

1. **고정밀 입력 데이터 생성**: Python 시뮬레이션과 동일한 합성 입력(엔코더 속도, VL53L0X 측정값)을 6자리 십진수 정밀도의 CSV 파일로 저장한다. 일반 로깅(2자리)에서는 부동소수점 누적 오차로 인해 검증 단계에서 실제 알고리즘 차이를 식별하기 어렵기 때문이다.
2. **Python 참조 출력 생성**: 동일 입력에 대해 Python 구현(kalman_filter.py)이 산출한 매 스텝 출력($\hat{x}$, K , r , P , R , S)을 참조값으로 저장한다.
3. **C 출력 생성**: 동일 입력 CSV를 C 구현(kalman_filter.c)이 PC 환경(gcc -O2)에서 처리하도록 한 후, 매 스텝 출력을 같은 형식으로 저장한다. PC 환경에서 검증함으로써 STM32 펌웨어의 외부 의존성(타이머, 인터럽트)을 제거하고 순수 알고리즘 코드만 비교한다.
4. **필드별 오차 비교**: Python과 C 출력의 매 스텝 절대 오차를 산출하고, 모든 필드에서 절대 오차 $< 10^{-3}$ 의 통과 기준을 충족하는지 확인한다. 단, innovation covariance S 에 대해서는 슬라이딩 윈도우 내 잔차 제곱 누적 특성을 고려하여 보조적으로 상대 오차 $< 0.001\%$ 의 기준을 추가 적용한다.

검증 결과

[표 3-5]에 Fixed KF와 CM-AKF의 검증 결과를 정리하였다. 두 알고리즘 모두 $\hat{x}$, K , r 에 대해 절대 오차 1×10^{-3} 이내를 충족하였다. Innovation covariance S 는 CM-AKF에서 최대 $4.76 \times 10^{-3} \text{ mm}^2$ 의 절대 차이를 보였으나, S 의 절대값(400~800 mm^2) 대비 상대 오차 0.001% 미만으로 실용적 영향이 없으며, 이는 슬라이딩 윈도우 내 잔차 제곱합의 float32 누적 특성에 기인한다. 이상의 1차 검증은 동기 입력 · 동일 정밀도 조건에서 알고리즘 코드의 등가성을 확인한 것이며, 센서 · 로깅이 통합된 실제 펌웨어에서의 등가성은 3.8.2절에서 재검증한다.

[표 3-5] Python ↔ C 등가성 검증 결과

알고리즘	$\hat{x}$ 절대오차 (mm)	K 절대오차	r 절대오차 (mm)	S 절대오차 (mm ²)	통과 기준
Fixed KF	4.88×10^{-4}	1.0×10^{-7} 미만	5.56×10^{-4}	3.1×10^{-5}	모든 필드 $< 10^{-3}$
CM-AKF	3.66×10^{-4}	1.0×10^{-6} 미만	4.08×10^{-4}	4.76×10^{-3}	$\hat{x} \cdot K \cdot r < 10^{-3}$ / S는 상대오차 < 0.001 %

3.8.2 2차 검증 – 통합 펌웨어 단계 등가성 재검증

3.8.1절의 1차 검증은 입력 정밀도와 행 정렬이 통제된 이상적 조건에서 수행되었다. 그러나 센서 읽기와 로깅이 하나의 200 Hz 메인 루프에 통합된 실제 펌웨어에서는 두 가지 조건이 달라진다. 첫째, C 펌웨어는 float32로, Python 참조 구현은 float64로 연산하므로, 수천 스텝 누적 시 mm 단위에서 0.1~0.5 수준의 차이가 수학적으로 불가피하게 발생한다. 둘째, 로깅이 50 Hz로 decimation되므로(3.6절) 200 Hz 동기 시뮬레이션과 행 단위로 1:1 정렬되지 않는다. 이 두 조건 하에서는 모든 필드에 일괄적으로 절대 오차 기준을 적용하는 방식이 통합 단계의 검증 잣대로 적합하지 않으며, 출력 필드를 그 특성에 따라 세 가지 방법으로 나누어 검증하였다.

방법 A는 상태 등가성 검증이다. 칼만 필터의 상태($\hat{x}$, P)와 동작(K , S)을 Python 재시뮬레이션과 행 단위로 비교한다. 이 값들은 정상 상태에서 거의 고정되므로 한 스텝의 정렬 오차가 비교 결과에 영향을 주지 않는다. `kf_estimate`, `kf_covariance`, `kalman_gain`, `innovation_cov` 네 항목 모두 float32 누적 오차로 설명되는 상대 오차 범위(상태 0.5 %, S 0.05 %) 이내에서 일치하였다.

방법 B는 residual의 자기 일관성 검증이다. residual은 매 스텝 부호와 크기가 크게 변하므로, decimation으로 한 스텝만 어긋나도 전혀 다른 값과 비교된다. 따라서 Python과의 행 단위 비교 대신, C 펌웨어 자체 출력만으로 칼만 필터 항등식 $r_k = z_k - \hat{x}_{k|k-1}$ 가 성립하는지 검증하였다. 정상 상태 200개 행 중 179개 행에서 항등식이 머신 입실론 수준(최대 약 7×10^{-15} mm)으로 성립하였으며, 나머지 21개 행은 200 Hz/50 Hz decimation 경계에서 규칙적으로 발생하는 산물로 알고리즘의 불일치가 아니다.

방법 C는 residual_mean과 residual_var의 구조적 등가 검증이다. 이 두 값은 CSV의 residual 컬럼이 소수점 셋째 자리로 반올림되고 decimation으로 윈도우 내용물을 복원할 수 없어 행 단위 수치 비교가 불가능하다. 그러나 C와 Python의 평균·분산 계산식이 코드 수준에서 동일하고(합/W, 제곱합/W - 평균²), 그 입력인 잔차가 방법 A·B로 이미 검증되었으므로, 동일한 입력에 동일한 함수를 적용한 결과의 등가성은 구성적으로(by construction) 성립한다.

세 방법을 종합한 결과, float32 기반 C 통합 구현은 float64 기반 Python 참조 구현과 수치적으로 등가함을 확인하였다. 특히 통합 펌웨어에서 측정된 정상 상태 공분산 $P = 19.506$ 과 칼만 게인 $K = 0.048766$ 은 E0 시뮬레이션 결과($P_{ss} \approx 19.51$, $K_{ss} \approx 0.0488$)와 소수점 셋째 자리까지 일치하여, 알고리즘 이식이 정확히 이루어졌음을 재확인하였다. 검증 방법과 결과를 [표 3-6]에 정리하였다.

[표 3-6] Python ↔ C 등가성 검증 결과

검증 방법	대상 필드	판정 기준	결과
A - 상태 등가성	kf_estimate, kf_covariance, kalman_gain, innovation_cov	상대 오차 (상태 0.5 %, S 0.05 %)	4개 필드 전부 통과
B - 자기 일관성	residual	항등식 $r = z - \hat{x}$ 검증	정상 행 179/200, 머신 입실론 수준 성립
C - 구조적 등가	residual_mean, residual_var	계산식 동일성 + 입력 검증 기반 논증	구성적으로 성립

3.8.3 TinyML-AKF의 등가성

TinyML-AKF의 경우, INT8 양자화 모델은 정수 연산만으로 추론을 수행하므로 결정론적이며, ST Edge AI Core 4.0가 생성한 MCU C 코드와 PC 측 TFLite Interpreter의 추론 결과는 동일 입력에 대해 bit-exact 일치한다. 이 결정론적 등가성은 본 연구에서 정량적 정확도 지표(RMSE, MAE, NIS, R 추정 RMSE)를 PC에서 INT8 모델로 사후 추론하여 산출하는 평가 방법론(5장)의 근거가 된다.

따라서 본 절의 등가성 검증은 모델 외부의 적응형 KF 구조에 한정하여, R 입력을 외부에서 동일하게 주입한 상태에서 KF 코드의 출력을 비교하는 방식으로 수행한다. 이 검증은 Fixed KF의 절차와 동일하며, 결과 또한 Fixed KF와 동일한 수준(모든 필드 $< 10^{-3}$)을 충족한다.

3.8.4 본 검증의 위상

본 등가성 검증은 알고리즘의 수치적 정확도를 확인한 단계이며, 임베디드 환경에서의 실시간 동작과는 별개의 검증이다. 후자는 (i) 200 Hz 루프 시간 예산 충족 여부, (ii) TinyML 추론 시간 < 0.5 ms 충족 여부, (iii) 통합 동작에서의 위치 추정 정확도 등을 포함한다. 이 가운데 200 Hz 루프 시간 예산과 IWDG · 로깅을 포함한 통합 동작 검증은 4.1.4절에서, TinyML 추론 시간과 위치 추정 정확도는 4장 실험에서 각각 평가한다.

4 장 실험 설계

4.1 임베디드 하드웨어

4.1.1 임베디드 하드웨어 플랫폼

본 연구의 실험은 STM32F446RE NUCLEO 보드(ARM Cortex-M4, 180 MHz, FPU 내장)를 MCU로 하는 2WD 모바일 로봇 플랫폼 위에서 수행된다. 구동계는 FIT0450 직류 기어드 모터 2개(내장 엔코더, 8 PPR, 감속비 120:1)와 TB6612FNG MOSFET H-bridge 드라이버로 구성되며, 좌/우 엔코더는 각각 TIM2(PA15/PB3)와 TIM4(PB6/PB7)의 Encoder Mode로 독립 카운트한다. KF Prediction의 운동학적 입력 u_k 는 좌/우 엔코더 속도의 산술 평균 $(v_{left} + v_{right})/2$ (mm/s)으로 정의한다.

전원은 두 계통으로 분리하여 구성한다. 첫째, MCU · 센서 · TB6612FNG 로직 전원은 7.4 V 2S LiPo 배터리를 YwRobot LM2596 기반 Buck Converter로 5.0 V 고정 출력으로 변환하여 공급하며, 모터 전원(VM)은 LiPo에서 직결한다. 둘째, HC-06 Bluetooth 모듈은 6 V 출력 배터리팩으로 별도 전원을 공급하여 무선 송신 부하가 MCU · 센서 전원 라인에 결합되지 않도록 분리한다. 두 계통의 GND는 신호 기준 일치를 위해 공통 접지한다.

[표 4-1] 실험 하드웨어 구성

구분	부품	주요 사양
MCU	STM32F446RE NUCLEO	Cortex-M4, 180 MHz, FPU; Flash 512 KB, SRAM 128 KB
ToF 센서	VL53L0X	I ² C (PB8/PB9), Continuous 모드 ~50 Hz, 측정 범위 ~2 m, FOV 25°
초음파 센서	HC-SR04	Trig: PA1 (GPIO), Echo: PA6 (TIM3_CH1 Input Capture), ~20 Hz, 빔폭 30°
엔코더 (좌)	FIT0450 내장 엔코더	8 PPR × 120:1 = 960 pulse/rev, TIM2 Encoder Mode (PA15/PB3), 200 Hz
엔코더 (우)	FIT0450 내장 엔코더	8 PPR × 120:1 = 960 pulse/rev, TIM4 Encoder Mode (PB6/PB7), 200 Hz

모터 드라이버	TB6612FNG	MOSFET H-bridge, VM 2.5-13.5 V, VCC 3.3/5 V, 1.2 A 연속 / 3.2 A 피크, Standby μ A급, PWM: TIM1 CH1(PA8) / CH2(PA9), 방향: PC8~PC11, STBY: PC12
전원 (메인)	7.4 V 2S LiPo + YwRobot LM2596 Buck Converter	Buck 출력: 5.0 V 공칭(부하 변동 $\pm 6\%$), 안정 2 A / 최대 3 A; MCU · 센서 · TB6612FNG 로직 전원
전원 (무선)	6 V 출력 배터리팩 (별도)	HC-06 Bluetooth 모듈 전용; 메인 전원과 GND 공통
무선 로깅	HC-06 Bluetooth UART	115200 baud, USART6 (PC6 TX $\rightarrow$ HC-06 RXD); TX DMA 더블 버퍼링, 50 Hz 로깅, pyserial 수신; 6 V 별도 전 원 공급(전원 행 참조)

4.1.2 Ground Truth 및 트랙 환경

데이터 로깅 시스템(HC-06 Bluetooth UART, DMA 더블 버퍼링, 50 Hz 28컬럼 CSV)의 구현 상세는 3.6절에서 기술하였다.

Ground Truth(GT)는 두 단계로 확보한다. ① 정적 캘리브레이션: 로봇을 시작점에 정지시키고 VL53L0X 측정값 100회의 평균을 기준 거리와 비교하여 센서 오프셋을 보정한다. ② 동적 GT: 시작점과 벽 사이의 거리를 줄자로 실측하여 시작 · 종료 절대 기준값으로 설정하되, 주행 구간 내 GT는 시작 · 종료 시점의 VL53L0X 측정값(각 첫 · 끝 5 frame 평균)을 거리 anchor로 사용하고 엔코더 누적값을 두 anchor 사이의 정규화된 보간 비율로 활용하여 산출한다. 즉 $GT(k) = ToF_{start} - (enc(k)/enc_{last}) \cdot (ToF_{start} - ToF_{end})$ 로 계산한다. 엔코더 스케일 팩터는 FIT0450 사양(8 PPR, 120:1 감속비 $\rightarrow$ 960 pulse/rev)과 바퀴 직경 실측값을 통해 $mm/pulse = \pi d/960$ 으로 결정한다. 정상상태에서 칼만 필터 추정치 VL53L0X 측정값에 수렴하는 특성을 이용하여 ToF 양 끝점을 절대 거리 anchor로 삼고, 엔코더는 절대 거리 기준이 아니라 구간 내 진행 비율을 분배하는 보간 변수로만 사용한다. 줄자(분해능 1 mm)의 절대 오차는 본 실험 단방향 거리 500 mm 대비 약 0.2 % 수준으로, RMSE 보고 수준(수 mm)에 대한 GT 자체 오차 기여는 무시 가능하다.

엔코더 단독 누적 거리를 절대 GT로 사용하는 방식은 수동 굴림 과정의 바퀴 슬립으로 인해 부정확하다. 전체 측정 run에서 엔코더 누적 이동량을 ToF 양 끝점 기준 실제 이동량과 대조한 결과, 엔코더는 실제 이동 거리의 약 75~94% 수준만을 반영하는 것으로 관측되었다. 따라서 엔코더 누적값을 절대 GT로 직접 사용할 경우 위치 추정 RMSE가 슬립량만큼 과대평가된다. 이에 본 연구는 슬립의 영향을 받지 않는 ToF 양 끝점을 거리 anchor로 두고 엔코더를 구간

보간에만 사용하는 위 방식을 GT로 채택하였으며, 이 한계와 GT 산정 방식은 5.3절에 함께 명시한다. E4는 로봇이 정지한 정적 시나리오이므로 엔코더 누적 오차가 발생하지 않으며, 구간 VL53L0X 측정값 평균을 GT로 사용한다.

실험 도로는 길이 약 1.5 m의 합판으로 구성하며, 그 위에 MDF 바닥판을 깔아 균일한 표면을 제공한다. 로봇은 시작점에서 500 mm 떨어진 벽을 향해 직선으로 이동하며, 도로의 나머지 약 1 m 구간은 시작점 뒤편 여유 공간으로 사용한다. 측정 대상 벽은 우드락 8절(약 270×390 mm) 패널로, VL53L0X FOV(25°) 기준 500 mm 거리에서의 실용 빔 지름(약 130 mm)을 충분히 덮는 반사 면적을 제공한다. 별도의 가이드레일은 설치하지 않으며, 짧은 거리·저속 수동 굴림 조건에서 직진성은 작업자가 직접 확보한다. VL53L0X의 주변 광 민감성을 고려하여 모든 실험은 동일 조명 조건(직사광선 차단)에서 수행한다.

4.1.3 센서 캘리브레이션

KF 측정 노이즈 공분산의 초기값(R_0)을 결정하기 위하여, 본 실험과 동일한 측정 환경(시작점-벽 500 mm, 흰 우드락 벽, MDF 합판 바닥)에서 약 5초간(~235 frame @ 50 Hz) 단방향 수동 굴림 1 run을 수행하는 동적 캘리브레이션을 E1 실험 직전에 수행하였다. 본 연구의 E1-E5 시나리오는 모두 동일한 시작점-벽 간격 500 mm의 단일 거리 조건에서 수행되므로(4.1.2절), 캘리브레이션 또한 정적 측정이 아닌 실험 환경과 동일한 동적 조건에서 수행하여 운용 환경의 측정 노이즈 특성을 직접 반영하였다.

본 캘리브레이션에서 Fixed KF의 잔차 표준편차 $\sigma \approx 4.49$ mm (정상상태 후반 100 샘플 기준)가 관측되어 $\sigma^2 \approx 20.1$ mm² 수준의 측정 노이즈 분산이 산출되었으며, 안전 마진을 포함하여 펌웨어에는 $R_0 = R_{\text{INIT}} = 24$ mm² 를 측정 노이즈 분산 초기값으로 하드코딩하였다. 본 정상상태 R 값은 동일 데이터의 Fixed KF innovation covariance (29.4 mm²) 및 Kalman gain (0.184351)을 통해 역산한 값($P_{\text{ss}} = R \cdot K / (1 - K) \approx 5.4$ mm², $R = 29.4 - 5.4 = 24.0$ mm²)과도 일관된다.

본 $R_0 = 24$ mm² 는 VL53L0X 데이터시트(ST DocID029104, Section 2.3)의 표준 조건 $\sigma \approx \pm 20$ mm 기준 가정값($R = 400$ mm²) 대비 약 17배 작은 값이다. 본 시스템의 운용 거리(500 mm)·표면 조건(흰 우드락)에서 ToF 센서의 실효 신뢰도가 데이터 시트의 보수적 가정보다 현저히 높음을 의미한다. 참고로 Phase 1 단독 검증(4.1.4절)의 100 mm 정적 거리 $\sigma = 1.53$ mm 결과와 본 캘리브레이션을 비교하면, 운용 거리에서의 동적 측정 σ 가 정적 100 mm 측정 σ 의 약 2.9배 수준임을 알 수 있다.

프로세스 노이즈 분산 Q 는 본 연구에서 모든 알고리즘에 대해 $Q = 1.0 \text{ mm}^2$ 로 고정한다. 이 값은 다음 두 가지 근거로 결정되었다. 첫째, 200 Hz 메인 루프($\Delta t = 5 \text{ ms}$)에서 좌·우 엔코더 평균을 운동학적 입력으로 사용할 때, FIT0450 엔코더의 분해능($\text{MM_PER_PULSE} \approx 0.054 \text{ mm}$)과 양측 엔코더 비대칭($\pm 1 \text{ pulse}$ 수준)을 고려한 한 스텝당 위치 예측 불확실성의 분산이 약 10^{-3} mm^2 수준으로 추정된다. 그러나 등속 가정에서 벗어나는 미소 가속·감속, 바퀴 슬립, 노면 미세 굴곡 등 미모델링 요인을 흡수할 여유를 두기 위해 이론치보다 약 3 자릿수 큰 $Q = 1.0 \text{ mm}^2$ 를 채택하였다. 둘째, 동일 Q 에 대해 $R_0 = 400 \text{ mm}^2$ 와 결합한 결과 E0 합성 데이터 시뮬레이션에서 NIS 신뢰구간 통과율이 95.5 % (목표 95 %에 근접)로 측정되어, 본 Q-R 조합이 $\chi^2(df = 1)$ 일관성 기준을 사실상 충족함을 사전 확인하였다.

1.2절에서 명시한 바와 같이 본 연구는 R 적응에 범위를 한정하므로 Q 는 모든 시나리오에서 고정값으로 운용하며, Q 적응에 대한 검증은 향후 연구로 남긴다.

4.1.4 하드웨어 통합 검증 프레임워크

본 시스템의 하드웨어 검증은 Phase 단위의 단계적 구조로 설계한다. 각 Phase는 한 번에 하나의 부품 또는 통합 계층만을 대상으로 하며, 명확한 Pass/Fail 기준을 사전에 정의하고, 해당 기준을 충족한 경우에만 다음 Phase로 진행한다. 이러한 Phase-gated 방식은 다수의 센서와 구동계를 동시에 결합할 경우 이상 발생 시 원인 부품을 특정하기 어렵다는 문제를 해소하기 위한 것으로, 통합 단계에서 문제가 관찰되더라도 이미 검증을 통과한 부품을 원인 후보에서 배제할 수 있게 하여 디버깅 범위를 좁히는 장치로 기능한다.

이 구조에 따라 검증은 두 단계로 구분된다. 첫째, 개별 모듈 검증(Phase 0-4-A)은 각 부품이 단독으로 사양을 충족하는지를 확인하는 단계이며, 전원·센서·구동계의 독립 동작을 보장한다. 둘째, 통합 검증(Phase 4-B, 5, 6, 7)은 모터 구동에 의한 전기적 노이즈가 센서 통신과 측정 정확도에 미치는 영향을 평가하고, 200 Hz KF 메인 루프와 50 Hz 무선 로깅 파이프라인이 실시간 제약을 충족하는지를 검증하는 단계이다. 본 절은 개별 모듈 검증과 Phase 4-B·5·6의 완료된 결과를 기술하고, Phase 7 통합 검증의 평가 기준을 함께 제시한다.

E1 1차 학습 데이터는 측정 시점 펌웨어의 두 가지 한계를 사후 보정하여 사용하였다. 첫째, F5 (Measurement Rate) 정의가 펌웨어 초기 구현에서 윈도우 내 `status==0` 비율이 아닌 변화율로 잘못 산출되었으므로, 별도 Python 스크립트로 정의대로 복원하였다. 둘째, Phase 4-B 모터 통합 과정에서 우측 모터 방향이 역으로 회전하여 모터 배선 +/-를 물리적으로 반전하였고, 이로 인해 동일 커넥터의 엔코더 신호 부호가 함께 반전되었다. 펌웨어 진입점 한 곳에서 부호를 보정하는 방식을 채택하였으나, 본 보정 적용 이전에 수집된 1차 데이터에는 동일한 Python

후처리로 부호 보정을 적용하였다. 두 보정은 KF/TinyML 알고리즘 영역이 아닌 입력 신호 영역의 처리이므로, 3.8절 Python ↔ C 등가성 검증과 E0 시뮬레이션 결과는 영향을 받지 않는다.

[표 4-2] 개별 모듈 검증 결과

Phase	검증 대상	Pass 기준	결과
0	Buck Converter + LiPo 2S	VCC $5.0 \pm 0.1V$, 부하 안정성	Pass (VCC 4.9-5.0V; 회귀 테스트로 HC-SR04 300mm 측정 $\sigma = 2.63mm$)
1	VL53L0X (I^2C ToF)	I^2C 0x29 응답, 측정 노이즈 특성 확인, 50Hz	Pass (100 mm 정적 $\sigma = 1.53$ mm, 55.20 Hz, Signal Rate 변별력 입증)
2	FIT0450 엔코더 $\times 2$	1회전 펄스 및 105mm 이동 $\pm 5\%$	Pass (1회전 M1 ~3870 / M2 ~3891 pulse, 105mm 이동 M1 -1.5% / M2 +1.2%)
3	HC-SR04 + TIM3 IC	297mm $\pm 10mm$, 비블로킹	Pass (297mm 측정 $\sigma = 5.6mm$, Echo 대기 중 메인 루프 블로킹 0 μs)
4-A	TB6612FNG 단독 구동	PWM/방향/STBY fail-safe, SoftStart	Pass (PWMA 0.98V @ 30%, fail-safe 부팅 STBY=L)

Phase 1에서 확인한 VL53L0X의 측정 노이즈 특성(100 mm 정적 $\sigma = 1.53$ mm)은 본 센서가 데이터시트 보수값보다 현저히 낮은 노이즈를 가짐을 입증하며, KF 측정 노이즈 초기값 R_0 자체는 4.1.3절에 기술한 바와 같이 본 실험 운용 거리(500 mm)에서의 정적 캘리브레이션으로 별도 확정한다. Phase 2의 mm/pulse 변환 계수(0.054 mm/pulse)는 3.6절 200 Hz 루프의 KF Prediction 입력으로 사용된다. Phase 3의 HC-SR04는 3.5.2절에 명시된 바와 같이 KF Update에는 관여하지 않으며, TinyML 모델의 F4(sensor disagreement) feature 입력 채널로만 활용된다. Phase 4-A의 fail-safe 부팅 동작은 4.2절 E1-E5 실험에서 모든 알고리즘이 동일한 구동 조건에서 비교될 수 있도록 보장한다.

개별 모듈 모두가 사양을 충족함을 확인한 뒤, 통합 검증을 단계적으로 수행하였다. Phase 4-B에서 모터 구동에 의한 센서 노이즈 영향을 정량화하고, Phase 6에서 200 Hz KF 메인 루프와 50 Hz 무선 로깅 파이프라인의 실시간 무결성 및 C↔Python 등가성을 검증하였으며, 그 결과를 [표 4-3]에 정리하였다.

[표 4-3] 통합 검증 평가 기준 및 결과

Phase	검증 대상	Pass 기준	결과
4-B	모터-센서 노이즈 결 합 (측정 값 기록)	모터 구동 중 $I^2 C$ 에러, VL53L0X σ 변화, Buck 5V 라인 안정성	측정 완료 - 정적 σ 2.47 mm, 주행 σ 3.10 mm (Phase 1 대비 1.6~2.0배), $I^2 C$ 에러 0/390, Status=0 100%
5	HC-06 + 50Hz CSV	18필드 무결성, drop $\leq 1\%$	Pass (drop 0/2750, 수신 seq gap 0, 18필드 무결성 99.9%)
6	센서+KF 통합 (모 터 OFF)	200Hz 루프 평균 $\leq 4.5ms$, 오버런 0/1000, CSV 18필드 무결성	Pass (본문 평균 1.14 ms · 최대 3.15 ms, body/ISR 오버런 0, drop 0/250, C $\leftrightarrow$ Python 등가성 확인)
7	수동 굴림 전체 통합 (모터 OFF)	200Hz 루프 실시간 성, 500mm 수동 굴 림 CSV 18필드 무결성 99%+, 굴림 속도 평균 · 표준편 차 산출, Bluetooth 로깅 드롭 $\leq 1\%$	Pass (조건부) - 200Hz 루프 30분 연속 정상, CSV 18 필드 무결성 99.55%, 굴림 속도 92.6 ± 33.9 mm/s 산출. Bluetooth 드롭은 굴림 중 10~20%로 기준($\leq 1\%$) 미달 - HC-06을 6 V 별도 전원으로 분리하였음에도 발 생함에 따라 전원 라인 결합이 아닌 모터 회전 발전 노이즈의 RF · 공통 접지 경로 EMI 기인으로 해석하며, seq 기반 위치 식별 가능하여 RMSE · TinyML 분석에 영향 없음(특성화된 한계)
7-A	TinyML 런타임 통합	ai_init 통과, INT8 추론 정상, 200Hz 루프 안정 성, CSV 28컬럼 무결성	Pass - E2 28컬럼 9 run + E4 30분 $\times$ 3 run, E4 누적 242,992회 추론에서 추론 mean 35.32 μs (std 0.007 μs , max 38.10 μs), 메인 루프 mean 1.24 ms (예산 4.5 ms의 27.5%), Body/ISR overrun 0, CSV TX drops 0, predict/update/inference 1:1 동기화 유지

30분 연속 측정 시 HC-06 무선 구간에서 약 7%의 프레임 손실이 관측되었다. 펌웨어 측 DMA TX는 누적 90,000 프레임을 0 drop으로 송신 완료하였으며, seq 필드를 통한 시간축 재구성으로 분석 정합성을 유지하였다. 본 손실은 무선 모듈의 장시간 송신 특성으로 평가하며, 3 run의 CM-AKF R 평균 CV가 0.53%로 유지된 점에서 RMSE · R^2 분석에 영향이 없음을 확인하였다 (E4 검증 결과).

Phase 7-A는 학습된 TinyML 모델을 ST Edge AI Core 4.0으로 STAI C 코드로 변환한 뒤 펌웨어에 통합하는 단계이다. 통합 과정에서 stai_network 핸들이 1-byte alias 타입이라는 점, 그리고 STAI_FLAG_PREALLOCATED 빌드에서 I/O 텐서가 activations 영역에 사전 할당되어 set_inputs/set_outputs 호출이 금지된다는 두 가지 비명시적 제약을 해결하였다. 입력 텐서는

6개 feature를 3.5.3절의 정규화 상수로 표준화한 후 INT8로 양자화하고, 출력 INT8 → float32 역양자화 → expm1 → [1.0, 10000.0] clamp 단계를 거쳐 kf_tinyml의 R 값으로 주입한다.

Phase 7 통합 검증이 완료된 후 4.2절의 E1-E5 물리 실험을 진행하며, E0는 하드웨어 검증과 독립된 합성 데이터 시뮬레이션이므로 본 절과 병렬로 사전 수행되었다.

4.2 실험 시나리오 E0-E5

세 가지 적응 알고리즘(Fixed KF, CM-AKF, TinyML-AKF)을 raw 센서값(baseline)과 함께 비교하기 위하여 총 6개 시나리오(E0-E5)를 설계하였다. E0는 합성 데이터를 이용한 KF 정상 수렴 검증 시뮬레이션이며, E1-E5는 실제 MCU 플랫폼에서 수행하는 동적 주행 시나리오이다. 각 시나리오의 목적, 물리적 조건 및 반복 횟수를 [표 4-4]에 정리하였다.

[표 4-4] 실험 시나리오 요약

ID	명칭 및 목적	물리적 조건	반복 / 예상 샘플
E0	Python 시뮬레이션 - 알려진 노이즈 조건에서 KF Predict-Update 루프의 정상 수렴 검증	합성 데이터: 초기 위치 100 mm, 등속 200 mm/s, $\sigma_{\text{meas}} = 20 \text{ mm}$ ($R = 400 \text{ mm}^2$), 난수 시드 42	1회, 2,000 스텝 (10 초, 200 Hz)
E1	정상 주차 접근 (Baseline) - 균일한 벽 표면 조건에서 세 알고리즘 기준 성능 비교의 기준선 확립	흰 우드락 8절 벽, 시작점-벽 500 mm, MDF 합판 바닥, 수동 굴림 (~약 100 mm/s) 단방향 주행	1차 5회(25컬럼 펌웨어, 학습용·Python 후처리 보정) + 2차 5회(28컬럼 TinyML 통합 펌웨어, 분석·평가용), 약 5 s/회, ~230 샘플/회
E2	벽 반사율 변화 - 주차 환경별 벽 표면 반사율 차이에 대한 R 적응 효과 검증	흰/검정 우드락 8절 + 투명 아크릴 B4(3 mm) 벽 3종 교체. 투명 아크릴은 ToF 광축에 대해 약 5~10° 기울여 설치 (range_status ≠ 0 유도 목적, Phase 1 사전 검증 기반)	1차 9회 + 2차 9회 (벽 3종 × 각 3회), 약 5 s/회, ~230 샘플/회
E3	동적 ToF 외란 - outlier 측정값이 KF 추정에 미치는 영향 stuck sensor 시 알고리즘 거동 검증	로봇이 벽으로부터 250 mm 지점에 진입하는 순간, 작업자가 100 mm 지점에 A4 사이즈 알루미늄 판을 ToF 빔 정면에 약 0.75~1초간 동적 진입/이탈 시킴. range_status는 0을 유지하나 측정값이 ~100~200 mm 영역의 outlier로 점프	5회(학습) + 5회(평가), 약 5 s/회, ~230 샘플/회
E4	정적 장기 안정성 - 정차 대기 상태에서 CM-	로봇 정지(모터 OFF), 흰 우드락 8절 벽 500 mm 거리 30분 연속 정적 측정	3회, 약 30 min/회, ~90,000 샘플/회


	AKF · TinyML-AKF의 R 드리프트 및 누적 오차 평가	(E1과 동일 벽 표면으로 변수 통제)	
E5	미지 벽 재질 일반화 - 학습되지 않은 벽 반사율 조건에 대한 일반화 능력 검증	회색 단면 우드락 8절 벽(학습 미포함 재질)	5회, 약 5 s/회, ~190 샘플/회

E1 · E2 · E3 시나리오는 동일한 물리적 셋업으로 측정 차수를 두 단계로 분리하여 수집하였다. 1차 측정은 Fixed KF · CM-AKF만 동작하는 25컬럼 펌웨어로 수집하여 TinyML 학습 데이터로 사용하고, 2차 측정은 TinyML이 통합된 28컬럼 펌웨어로 재수집하여 Fixed/CM/TinyML 세 알고리즘이 동일 frame을 공유하는 라이브 동작 검증과 분석 · 평가에 사용한다. 두 차수의 분리 운영은 학습 데이터와 평가 데이터의 펌웨어 버전 · 측정 시점을 명확히 구분하여 data leakage를 방지하기 위함이다. 다만 E1 1차 측정은 Phase 4-B 모터 통합 이전 시점에 수집되었으므로, Phase 4-B 모터 배선 반전 과정에서 발생한 우측 엔코더 부호 반전과 F5(Measurement Rate) 정의 일관성 두 항목에 대하여 별도 Python 후처리로 보정한 후 학습에 사용하였다. E2 · E3 1차 측정은 위 두 항목이 펌웨어에 반영된 시점 이후이므로 추가 후처리 없이 원시 데이터를 사용한다. E1 후처리 보정은 모두 입력 신호 영역의 처리이므로 3.8절 Python ↔ C 등가성 검증과 E0 시뮬레이션 결과에는 영향을 주지 않는다. E4 · E5는 Phase 7-A TinyML 통합 펌웨어로만 측정한다.

E0는 하드웨어 배포에 앞서 KF의 Predict-Update 루프가 원리적으로 정상 동작함을 통제된 환경에서 검증하는 시뮬레이션 시나리오이다. 초기 위치 100 mm에서 약 200 mm/s 수준의 수동 굴림 운동을 2,000 스텝(10초, 200 Hz) 동안 합성하며, 측정 노이즈 분산 $R = 400 \text{ mm}^2$ 는 VL53L0X 데이터시트(ST DocID029104, Section 2.3) 기준 $\sigma = \pm 20 \text{ mm}$ 로부터 도출하였다. 시뮬레이션에서는 R 을 실제 측정 노이즈와 일치시켜 이상적 조건을 구성하였으며, 이를 통해 KF가 Riccati 방정식의 이론적 정상상태로 수렴하는지, NIS 기반 필터 일관성이 충족되는지를 확인한다. 실제 환경에서는 표면 반사율, 주변 조도, 측정 거리 등에 의해 센서 노이즈가 변동하므로, 이를 실시간으로 보정하는 적응형 메커니즘이 본 연구의 핵심 동기가 된다.

E0 시뮬레이션 결과, 필터 추정값의 RMSE는 센서 원시값 20.04 mm에서 4.26 mm로 78.7% 개선되었다. 정상상태 오차 공분산 $P_{ss} = 19.51 \text{ mm}^2$ 는 이산 대수 Riccati 방정식의 해석해와 일치하며, 정상상태 칼만 게인 $K_{ss} = 0.049$ 는 매 스텝 새로운 측정값의 약 5%만 상태 추정에 반영됨을 의미한다. NIS 값의 95.5 %가 $\chi^2(df = 1)$ 95% 양측 신뢰구간([0.00098, 5.024]) 내에 위치하여 필터가 적절히 튜닝되었음을 확인하였다. 수렴은 슬라이딩 윈도우 $\text{RMSE}(W = 20)$ 가

처음으로 $\varepsilon = 5 \text{ mm}$ 이하로 내려가는 시점으로 정의하였으며, E0에서의 수렴 시간은 0.120초(24 스텝)였다. $\varepsilon = 5 \text{ mm}$ 는 이론적 정상상태 하한($\sqrt{P_{ss}} = 4.42 \text{ mm}$)의 약 1.13배로, 13%의 마진을 부여한 값이다. E0 결과는 [그림 4-1]에 제시하였다.



[그림 4-1] E0 시뮬레이션 결과 그래프

슬라이딩 윈도우 크기는 $W = 20(100 \text{ ms})$ 을 선택하였다. E0 시뮬레이션에서 $W = 20$ 과 $W = 30$ 을 비교한 결과, 분산 추정 안정성 차이는 미미하였으나(변동 계수 0.358 vs 0.299) $W = 20$ 이 환경 변화 시 분산 반응을 1 스텝(5 ms) 더 빠르게 수행하였으며, 이는 적응형 R 조절 메커니즘에 유리한 요소이다.

E1은 흰 우드락 벽을 향해 약 100 mm/s 수준의 수동 굴림으로 500 mm 직선 구간을 단방향 수동 굴림하는 정상 조건 시나리오로, 세 알고리즘의 기준 성능을 확립한다. E1은 측정 차수를 두 단계로 분리하여 수행하였다. 1차 측정(5 run)은 Fixed KF · CM-AKF만 동작하는 25컬럼 펌웨어로 수집한 후, F5 정의 일관성 확보를 위한 후처리와 엔코더 부호 보정(Phase 4-B 통합 시 모터 배선 변경으로 발생한 부호 반전)을 별도 Python 스크립트로 적용하여 TinyML 학습/평가 데이터로 사용한다. 2차 측정(5 run)은 TinyML이 통합된 28컬럼 펌웨어로 재측정하여,

Fixed/CM/TinyML 세 알고리즘이 동일 frame을 공유하는 라이브 동작 검증과 시간 동기 비교에 사용한다.

E2는 VL53L0X가 측정하는 벽 표면의 반사율을 변경하여 측정 노이즈 환경 변화에 대한 R 적응 능력을 검증한다. 흰 우드락 8절 / 검정 우드락 8절 / 투명 아크릴 B4 3 mm 세 가지 벽 표면을 1차·2차 각각 9 run(벽별 3 run $\times$ 3종) 수집한다 ([표 4-4] 참조). 흰 우드락은 정상 반사율 baseline, 검정 우드락은 낮은 반사율, 투명 아크릴은 극저 반사율 환경을 제공한다. 본 시나리오에는 단일 run 내 R 시간적 변화가 아니라 run 간 R 환경 차이를 통해 알고리즘 강인성을 비교하며, 시간적 R 적응 시계열 분석은 E3 시나리오에서 수행한다.

본 연구 설계 단계에서는 투명 아크릴이 range_status $\neq$ 0 형태의 부분 신호 손실을 유발할 것으로 예상하였으나, 측정 결과 VL53L0X의 940 nm 광원이 일반 투명 아크릴에 대해 부분 투과성을 가지므로 9 run 전부터 range_status $\neq$ 0 관측은 0건이었다. 대신 IR 광의 부분 투과 및 정반사 성분이 결합한 형태로 측정 노이즈 분산이 재질에 따라 분리되었으며, 2차 측정 9 run의 CM-AKF가 추정한 측정 노이즈 공분산(전체 평균)은 흰 우드락 130.71 / 검정 우드락 116.44 / 투명 아크릴 127.27 mm² 로 세 표면이 유사한 R 영역에 분포하였다 (시나리오별 상세는 5.1.3절 참조). 따라서 range_status $\neq$ 0 분포의 학습/평가는 E3 시나리오로 일원화된다.

E3는 로봇이 벽으로부터 250 mm 지점에 진입하는 순간, 작업자가 100 mm 지점에 A4 사이즈 알루미늄 판을 ToF 빔 정면에 약 0.75~1초간 동적으로 진입시키는 시나리오이다. 알루미늄의 940 nm IR 강반사 특성으로 인해 측정값이 본래 벽 거리(~250 mm)에서 알루미늄 표면 거리(~100~200 mm)로 급격히 점프하는 outlier가 발생한다. 이때 range_status는 0을 유지하나 잔차가 지속적으로 큰 값을 가지므로, 2.2.3절에서 기술한 CM-AKF의 stuck sensor 구조적 한계 - 잔차 단일 통계로는 환경 노이즈와 센서 이상을 구분할 수 없는 상황 - 을 실물 환경에서 재현한다. TinyML-AKF는 잔차 폭증 이전에 signal rate와 sensor disagreement의 변화로 선제 감지가 가능한지를 본 시나리오에서 검증한다.

초기 설계에서는 검정 우드락 8절 차단재를 정적 측면 설치하는 방식을 가정하였으나, 사전 시험 5회에서 검정 우드락의 940 nm IR 부분 반사 특성으로 range_status $\neq$ 0이 유발되지 않음이 실측으로 확인되어 동적 알루미늄 차단 메커니즘으로 변경하였다. 검정 우드락의 가시광 흡수율과 IR 흡수율이 다르다는 점이 발견의 핵심이며, E2 검정 우드락 9 run에서도 range_status $\neq$ 0 = 0건이었던 점이 동일한 발견의 사전 증거에 해당한다.

E4는 로봇을 시작점에서 정지시킨 채(모터 OFF) 500 mm 거리의 벽을 30분간 연속 측정하는 정적 안정성 시나리오이다. 타이머 오버런, IWDG refresh 누락 등의 장기 요인에 의한 R 드리프트, 메모리 누수, 추론 지연 누적, 메인 루프 실시간 제약 유지 여부를 분석하며, 수집

데이터는 모두 평가용으로만 사용하고 TinyML 학습 데이터에서 제외한다. 벽 표면은 E1과 동일한 흰 우드락 8절을 사용하여 표면 변수를 통제함으로써 장기 요인만을 분리하여 평가하였다.

E5는 학습 데이터에 포함되지 않은 벽 표면 반사율 조건에서 TinyML-AKF의 일반화 능력을 평가한다. 회색 단면 우드락 8절 5T를 벽으로 사용하여 5회 반복 측정하며, 본 재료는 가시광 기준 흰/검정 우드락의 중간 반사율로 선정되었다. 실측 signal_rate는 run별 평균 12.6~20.2 Mcps (5 run 평균 16.3 Mcps, max 29~43)로, 흰 우드락(E1 18.1 / E2 20.5 Mcps)과 검정 우드락(E2 11.1 Mcps) 사이의 중간 영역에 위치하여 가시광 기준 중간 반사율 선정 의도와 부합하였다. E2 평가 데이터(투명 아크릴)와 교차 분석함으로써 학습된 반사율 조건과 미지 조건 간 성능 차이를 정량화한다.

전체 데이터 규모는 E0 시뮬레이션 2,000 샘플, E1 1차·2차 각 5 run, E2 1차·2차 각 9 run, E3 1차·2차 각 5 run, E5 5 run 수집 시 회당 약 230 샘플 기준 합계 약 1만 샘플, E4의 3회 수집 시 약 270,000 샘플로, 총 약 28만 샘플 규모의 데이터셋이 구축된다.

4.3 평가 지표

세 알고리즘(Fixed KF, CM-AKF, TinyML-AKF)의 성능 비교를 위해 정확도 지표와 실시간성 지표를 분리하여 산출한다. 정확도는 풀 통합 펌웨어가 라이브 측정으로 산출한 CSV의 알고리즘별 추정 컬럼(fixed_estimate_mm / cm_estimate_mm / tinyml_estimate_mm)을 PC에서 후처리 분석하며, 실시간성은 MCU에서 직접 측정한다. 분리 산출의 정당성은 4.3.3절에서 기술한다.

4.3.1 정확도 지표

[표 4-5] 평가 지표 정의

지표	수식 / 기준	설명 및 적용 시나리오
RMSE	$\sqrt{\left(\frac{1}{N} \sum (x_k - x_k^{GT})^2\right)}$	위치 추정 정확도의 주 지표. Raw 센서값과 세 알고리즘(Fixed KF, CM-AKF, TinyML-AKF) 전 시나리오 공통 산출.
MAE	$\frac{1}{N} \sum x_k - x_k^{GT} $	이상치 영향이 적은 보조 지표. RMSE와 함께 보고.
NIS pass rate	$(v_k^2)/S_k \in [0.00098, 5.024] \text{ 비율}$	필터 일관성(consistency) 검증. S_k 는 innovation_cov 컬럼 직접 사용 또는 $P=R \cdot K/(1-K)$ 역산. $\chi^2(df=1)$ 95% 양측 신뢰구간. CM-AKF의 W=20 윈도우 미충전 초기 구간은 산출에서 제외.

정상상태 RMSE (RMSEss)	측정 후반 1초(50 frame) RMSE	알고리즘 수렴 이후 안정 구간 정확도. E1 · E2 · E3 · E5 적용 (E4 제외, 정적).
수렴 시간 (Tconv)	$RMSE(t) \leq 1.1 \times RMSEss$ 최초 시각	초기 과도 상태 지속 시간. RMSEss는 정상 상태 (steady-state) RMSE. E1 · E2 · E3 적용.
R 거동 분석	E2 표면별 R 평균, E3 R 폭주 시계열, E4 R drift CV, TinyML 라벨 추적도 (MAE/MAPE)	CM-AKF · TinyML-AKF 전용. cm_R이 양 알고리즘 산출값이자 TinyML 학습 라벨이므로 R 추정 RMSE는 self-reference로 무의미. 4가지 분리 평가로 대체.
추론 시간 (TinyML 전용)	< 0.5 ms (목표) DWT 사이클 카운터 측정	MCU 실시간 제약(hard real-time, RQ1) 검증. 풀 통합 펌웨어(Fixed/CM/TinyML 3-way 병렬 동작 + 28컬럼 CSV 로깅)에서 E4 정적 안정성 시나리오 3 run × 30분 누적 242,992회의 실제 feature 기반 추론에 대해 DWT 사이클 카운터로 직접 측정. 목표: 90,000 사이클(0.5 ms, 180 MHz 기준) 이내.

RMSE와 MAE는 50 Hz로 로깅된 CSV 데이터의 알고리즘별 추정 컬럼(fixed_estimate_mm / cm_estimate_mm / tinymml_estimate_mm)과 gt_distance_mm 열을 사용하여 파이썬으로 산출한다. Raw 센서값(VL53LOX)도 동일하게 산출하여 KF 효과의 기준선으로 보고한다.

NIS는 $H = 1$ 인 1차원 스칼라 모델에서 $v_k = z_k - \hat{x}_k^-$ (KF Update 이전 예측 잔차)와 $S_k = P_k|_{k-1} + R_k$ 를 사용하여 v_k^2/S_k 로 계산한다. CSV의 innovation_cov(S_k) 컬럼을 직접 사용하며, 부재 시 $P_k|_{k-1} = R_k \cdot K_k / (1 - K_k)$ 로 역산한다. NIS가 $\chi^2(df = 1)$ 95% 양측 신뢰구간 [0.00098, 5.024] 내에 위치하는 비율을 pass rate로 보고하며, CM-AKF의 윈도우 미충전 초기 $W = 20$ 구간은 산출에서 제외한다. 다만 TinyML-AKF의 NIS는 풀 통합 펌웨어의 28컬럼 CSV에 tinymml_kalman_gain · tinymml_innovation_cov 컬럼이 포함되지 않아 본 연구에서는 산출에서 제외하며, 표 5-2의 TinyML-AKF 행 NIS 열은 "-"로 표기한다.

정상상태 RMSE(RMSEss)는 알고리즘 수렴 이후 안정 구간의 정확도를 정량화하는 독립 지표로, 측정 후반 1초(50 frame) 슬라이딩 윈도우의 RMSE로 산출한다. E1 · E2 · E3 · E5에 공통 적용하며, E4는 정적 시나리오로 제외한다.

수렴 시간(Tconv)은 시동 직후 과도 구간 지속 시간을 정량화한다. 직전 1초(50 frame) 슬라이딩 윈도우의 RMSE가 $1.1 \times RMSEss$ 이하로 최초 진입하는 시각으로 정의하며, E1 · E2 · E3 · E5에 적용한다. E0 시뮬레이션은 이론적 정상상태 하한이 해석적으로 알려져 있으므로($\sqrt{P_{ss}} = 4.42$ mm), 이에 13% 마진을 부여한 절대 임계값 $\varepsilon = 5$ mm를 사용한다.

R 거동 분석은 CM-AKF · TinyML-AKF가 산출한 R 시계열의 정성 · 정량 분석이다. cm_R 이 양 알고리즘의 산출값이자 TinyML 학습 라벨(3.5.4절)이므로 R 추정 RMSE 산식($R - R_{label}$)은 self-reference로 무의미하다. 대신 다음 네 가지로 R 추정의 품질을 분리 평가한다: (i) E2 표면별 R 평균(재질 단조성), (ii) E3 R 폭주 시계열(CM 발산 vs TinyML 거동 비교), (iii) E4 R 30분 drift CV(run-to-run 재현성), (iv) TinyML 라벨 추적도(cm_R 대비 MAE/MAPE, 4.3.5절 ablation에서 활용). 보조 지표로 Max Error 및 divergence 여부를 함께 보고한다.

4.3.2 실시간성 지표 (MCU 실측)

실시간성은 두 관점으로 분리하여 분석한다. (i) Hard real-time – MCU 추론이 메인 제어 루프 시간 제약(<5 ms) 내 완료되는가, (ii) Online streaming – 센서 갱신 주기(VL53LOX 50 Hz, 엔코더 200 Hz)에 동기되어 결과가 갱신되는가. 두 관점 모두 1장의 "실시간(real-time)" 정의에 부합한다.

(1) Hard real-time

- TinyML 추론 시간 – 목표 < 0.5 ms (180 MHz 기준 90,000 사이클 이내). DWT 사이클 카운터로 매 추론 호출 전후 사이클 차이를 측정하며, 폴 통합 펌웨어 E4 시나리오에서 3 run × 30분 누적 242,992회 추론을 직접 측정한다.
- 메인 루프 시간 – 200 Hz KF 루프의 평균 · 최대 실행 시간. 폴 통합 펌웨어에서 측정한다.
- 오버런 수 – 5 ms 주기를 초과한 횟수. 실시간 적용 가능성 판단의 핵심 지표이다.

(2) Online streaming

- CSV drop rate – 50 Hz BT 로깅 누락 비율. 폴 통합 펌웨어 27 run 라이브 측정으로 검증한다.
- r_tinym 매 루프 갱신 확인 – TinyML이 추정된 R 값이 폴 통합 펌웨어 실행 중 매 KF 루프마다 정상 갱신되는지 확인한다.

4.3.3 평가 방식 및 정당성

(1) 정확도 평가 - MCU live CSV의 PC 후처리 분석

RMSE / MAE / NIS pass rate / RMSEss / Tconv / $R^{\wedge}$ 거동 분석은 모두 폴 통합 펌웨어가 라이브 산출한 CSV의 알고리즘별 추정 컬럼을 PC에서 후처리 분석하여 산출한다. 세 알고리즘이 동일 MCU에서 동일 입력에 대해 동시 실행되므로(3.6절) 공정 비교가 보장된다. PC 재추론이 아닌 MCU live 값을 직접 사용하므로 INT8 양자화 · 부동소수점 순서 · 메모리 alignment 등 MCU 환경 변수가 결과에 그대로 반영된다.

(2) 추론 시간 평가 - MCU 직접 측정

TinyML 추론 시간은 폴 통합 펌웨어가 E4 시나리오에서 라이브 측정한 DWT 사이클 카운터 값을 사용한다. 정확도 지표는 PC에서 산출하더라도, 실시간 적용 가능성은 실제 MCU 실행 시간을 기준으로 판단해야 하기 때문이다.

(3) Ablation 평가 - PC 사후 추론

Ablation 비교 모델(3-feature)은 펌웨어에 탑재되지 않으므로 학습된 TFLite 모델을 PC에서 동일 평가 데이터셋에 사후 추론하여 6-feature 메인 모델과 비교한다. STM32Cube.AI / ST Edge AI Core 4.0의 INT8 양자화는 bit-exact 보장이 제공되며, 3.8절 Phase 6 등가성 검증에서 C $\leftrightarrow$ Python 모든 KF 필드의 절대 오차가 10^{-3} 이내임을 확인하였으므로 PC 추론 결과가 MCU 동작과 등가임이 보장된다.

4.3.4 시나리오별 분석 매핑

각 시나리오의 평가 목적이 다르므로, 모든 지표를 동일하게 적용하지 않고 시나리오 특성에 맞게 분석한다 (시나리오 정의는 [표 4-4] 참조).

[표 4-6] 시나리오별 분석 매핑

시나리오	분석 목적	정확도 지표	$R^{\wedge}$ 거동 분석
E0	KF Predict-Update 루프 정상 수렴 검증	RMSE, MAE, NIS pass rate, Tconv(ε =5 mm)	—
E1	정상 주차 접근 baseline 성능 확립	RMSE, MAE, NIS pass rate	—
E2	벽 반사율 변화에 대한 R 적응 능력	RMSE, MAE, NIS, Tconv	표면별 R 단조성

시나리오	분석 목적	정확도 지표	R^2 거동 분석
E3	ToF 일시 차단 시 CM-AKF 구조적 한계	RMSE, Max Error, divergence, Tconv	R 폭주 시계열
E4	30분 정적 R drift · 메모리 · 추론 지연 누적	RMSE, MAE, 메인 루프 오버런	30분 drift CV
E5	학습 분포 외 회색 우드락 일반화	RMSE, MAE	TinyML 라벨 추적도

실시간성 지표(4.3.2절)는 E1~E5 전반에 걸쳐 공통 산출되며, 특히 E4에서 장시간 누적 거동을 집중 분석한다.

4.3.5 Ablation 분석 방식

TinyML-AKF의 입력 feature 기여도를 정량화하기 위해 6-feature 메인 모델과 잔차 통계만 사용한 3-feature 축소 모델을 비교한다. 5-feature(F6 제외) 모델은 본 연구의 시간 제약상 생략하며, 두 극단(전체 vs 잔차 통계만) 비교만으로도 multi-modal feature의 효과를 정량화할 수 있다.

(1) Feature set 구성

[표 4-7] Ablation feature set 구성

구성	포함 feature	의도
6-feature (full)	F1 residual, F2 residual variance, F3 residual mean, F4 sensor disagreement, F5 measurement rate, F6 signal rate	TinyML-AKF 본 구성
3-feature (ablation)	F1 · F2 · F3 (잔차 통계만)	CM-AKF가 사용하는 정보 채널과 동일 구성, multi-modal feature 효과 정량화

(2) 학습 · 검증 · 평가 데이터 분할

[표 4-8] Ablation 데이터 분할

구분	구성	rows
학습 (Train)	E1 run01-03 + E2 white/black/acryl run01 + E2 white · black run02 + E3 run01-02 (총 10 run)	2,156
검증 (Val)	E2_acryl_run02 + E3_run03 (총 2 run)	433
평가 (Test)	E2 white/black/acryl run03 + E3 run04-05 (총 5 run)	1,072

본 분할은 run 단위 분리 원칙(같은 run 내부 random split 금지)을 유지하며, [표 4-6] 원본의 표면당 Run 4-5 평가 가정은 E2가 표면당 3 run만 측정되었으므로 표면당 Run 03 평가로 조정하였다. 정규화 파라미터(mean · std)는 두 모델 모두 E1 Run 1-3의 분포로 산출하여 동일 적용한다 (3.5.3절).

(3) 평가 지표

[표 4-9] Ablation 평가 지표

지표	의미
MAE_R	TinyML R 이 cm_R 라벨을 추적한 절대 평균 오차
MAPE_R	TinyML R 의 비례 오차 (큰 R 구간에서의 영향 차이 식별)

지표를 함께 비교함으로써 단순한 절대 오차뿐 아니라 R 분포 전 구간에서의 추정 품질 차이를 분리해낸다. 위치 추정 RMSE는 5장 시나리오별 분석에서 별도 보고한다.

(4) Ablation 결과

[표 4-10] Ablation 결과

모델	파라미터	TFLite	Test MAE_R (f32)	Test MAPE_R (f32)	Test MAE_R (INT8)	INT8 차이
6-feature (메인)	257	3.20 KB	357.31 mm ²	34.3%	273.13 mm ²	-23.6%
3-feature (ablation)	209	3.16 KB	387.72 mm ²	20.1%	393.94 mm ²	+1.6%

절대 오차(MAE_f32)는 6-feature가 30.41 mm² 작으며, INT8 양자화 후 MAE_R 역시 6-feature가 273.13 mm² 로 3-feature 393.94 mm² 보다 낮았다. 반면 비례 오차(MAPE)는 3-feature가 20.1%로 6-feature 34.3%보다 낮아, 절대 오차와 비례 오차가 서로 다른 해석을 제공한다. F5(measurement rate)는 학습 데이터 19 run 전부에서 range_status ≠ 0 발생률이 0%로 측정되어 사실상 상수(=1.0)가 되었으므로, 본 ablation은 실질적으로 F4(sensor_disagree) · F6(signal_rate) 추가의 가치를 측정한 것이며, 본 학습 데이터 분포에서 이들 multi-modal feature의 일반화 우위는 제한적인 것으로 평가된다 (5장 RQ3 해석 참조).

6-feature 메인 모델의 INT8 양자화 후 MAE 변화율 -23.6%는 사전 검증 단계에서 설정한 ±5% 목표를 초과한다. 그러나 본 차이는 *R* 값의 절대 수치 차이이며, 5장의 위치 추정 RMSE 결과에서 INT8 모델로 동작하는 TinyML-AKF가 발산 없이 CM-AKF와 동등 수준(E1 · E4 · E5)에서 동작함이 확인되었으므로, 양자화 오차가 위치 추정 안정성을 결정적으로 훼손하지 않음을 실험적으로 확인한다.

4.4 데이터 분할 전략

TinyML-AKF의 학습 · 검증 · 평가 데이터를 설계하는 데 있어, 시간적 상관성(temporal correlation)으로 인해 무작위 분할이 적합하지 않다. 동일 시나리오 내에서 인접한 샘플은 높은 자기상관을 가지므로, 런(run) 단위 분할 방식을 채택하여 데이터 누수(data leakage)를 방지한다.

[표 4-11] 시나리오별 데이터 분할 전략

ID	총 반복	TinyML 학습	알고리즘 평가	비고
E0	1회	미사용	파이썬 시뮬레이션 검증	F4(sensor disagreement) · F5(measurement rate) · F6(signal rate) 3개 feature의 입력 신호(VL53L0X signal rate · range status, HC-SR04 거리)가 부재하여 TinyML 학습/평가에 사용 불가

E1	1차 5회 + 2차 5회	1차 Run 1-3	1차 Run 4-5 (메인 모델 hold-out 평가 + ablation 비교) + 2차 Run 1-5 (라이브 3-way 검증)	정규화 파라미터(mean/std) 산출 기준 데이터; 1차는 엔코더 부호 보정 · F5 정의 복원 Python 후처리 적용
E2	1차 9회 + 2차 9회 (벽 3종 × 각 3회)	1차 벽별 Run 1-2	1차 벽별 Run 3 (메인 모델 hold- out 평가 + ablation 비교, PC 사후추론) + 2차 벽별 Run 1-3 (라이브 3-way)	재질별 R 분포 분리 (2차 측정 cm_R 평균 현 130.71 / 검정 116.44 / 투명 아크릴 127.27 mm ² , 5.1.3절 참조); 투명 아크릴은 ToF 광축에 대해 5~10° 기울여 설치(range_status ≠ 0 유도 목적)
E3	1차 5회 + 2차 5회	1차 Run 1-3	1차 Run 4-5 (메인 모델 hold-out 평가 + ablation 비교, PC 사후추론) + 2차 Run 1-5 (라이브 3-way)	알루미늄 동적 차단; stuck sensor 시 cm_R clamp 도달 패턴 포함
E4	3회	미사용	전량 평가 (안정성)	장기 드리프트 분석 전용; R_label 의미 없음

E5	5회	미사용	전량 평가 (일반화)	미지 표면 일반화 검증; E2와 교차 평가 가능
----	----	-----	----------------	-------------------------------

TinyML 모델의 학습에는 E1·E2·E3의 Run 1-3을 사용하고, E1·E2·E3의 hold-out run(E1 Run 4-5, E2 벽별 Run 3, E3 Run 4-5)은 메인 6-feature 모델의 일반화 성능 평가와 3-feature ablation 모델과의 비교 평가에 공통으로 사용한다 (PC 사후추론).

E1은 측정 차수를 두 단계로 분리하여, 1차 측정 5 run은 학습/ablation 평가에 사용하고 2차 측정 5 run은 TinyML 통합 펌웨어로 재측정하여 Fixed/CM/TinyML 세 알고리즘의 라이브 3-way 비교에 사용한다 (4.2절 E1 본문 참조). 1차 데이터는 1차 측정 펌웨어 시점의 F5 정의 불일치와 Phase 4-B 통합 과정에서 발생한 엔코더 부호 반전을 별도 Python 후처리 스크립트로 보정하여 학습 데이터 일관성을 확보하였다.

E4는 장기 안정성 전용 시나리오로 학습 데이터에서 완전히 제외한다. E5는 전량을 평가 전용으로 사용하여 TinyML-AKF의 미지 표면 일반화 능력을 검증하며, E2 평가 데이터와 교차 분석함으로써 학습에 포함된 반사율 조건과 미지 조건 간 성능 차이를 정량화한다.

정규화 파라미터(각 특징의 평균·표준편차)는 E1 학습 데이터(Run 1-3)만을 이용하여 fit하고 MCU 펌웨어에 상수로 하드코딩하며, 동일 변환을 E1·E2·E3 학습/평가 데이터 전체에 적용한다. F5는 E1 학습 데이터에서 $\text{std}=0$ 이므로 $\text{std_safe}=1.0$ 으로 매핑하여 모든 입력값이 모델에서 상수 0으로 정규화된다 (3.5.3절 참조). transform 단계에서 정규화 후 범위 밖 값은 clip하지 않고 그대로 사용하여, 학습 데이터 분포 밖 신호를 모델이 OOD(out-of-distribution) 정보로 활용할 수 있도록 설계하였다. INT8 양자화 이후 모델 정확도를 보존하기 위하여, TFLite float32 모델과 INT8 모델을 동일 테스트 세트에서 평가한다. 사전 검증 단계의 목표는 R 추정값 기준 오차 $\pm 5\%$ 이내였으나, 실측 결과 6-feature 메인 모델은 -23.6% (4.3.5절 표 4-10) 차이가 관측되었다. 본 차이가 위치 추정 RMSE에 미치는 영향은 5장 시나리오별 결과에서 별도로 평가한다.

또한 1.3절에서 기술한 ablation study를 위해, E1·E2·E3 학습 데이터(각 시나리오 Run 1-3)를 대상으로 feature 조합을 달리한 두 모델을 학습한다. 전체 6-feature 메인 모델(MCU 실시간 추론용, 펌웨어 배포)과 잔차 통계만 사용하는 3-feature ablation 모델(F1·F2·F3; tof_residual, tof_residual_var, tof_residual_mean; PC 사후추론용)을 학습한 뒤, 평가 데이터에서 R 추정 RMSE/MAE와 위치 추정 RMSE를 비교하여 잔차 통계 외 feature(F4·F5·F6)의 기여도를 분석한다. 5-feature 모델은 일정 제약으로 본 연구에서는 생략한다. 메인 모델은 RQ1 검증을 위해 반드시 MCU 실시간 추론이어야 하지만, ablation 모델은 RQ3에 대한 비교 도구이므로 PC 사후추론으로 평가하여도 논문의 RQ1/RQ2 무결성에 영향을 주지 않는다. 두 모델 모두 동일한 hold-out 데이터에서 평가하여 비교 공정성을 확보하며, 메인 모델의 hold-out 성능은 학습 데이터와 분리된 일반화 능력 자체를 평가하는 지표로도 활용한다.

5장 실험 결과 및 결론

5.1 실험 결과

본 절에서는 4장에서 설계한 E0~E5 시나리오의 정량적 측정 결과를 객관적으로 제시한다. 결과에 대한 해석과 연구 질문 답변은 5.2절에서 다룬다.

5.1.1 E0 시뮬레이션 결과

E0 시뮬레이션은 KF의 Predict-Update 루프가 원리적으로 정상 동작함을 통제된 합성 환경에서 사전 검증한 시나리오이다. 측정 결과는 4.1.3절에 상세히 기술하였으며, 본 절에서는 5장의 알고리즘 비교 논의의 기준점이 되는 핵심 수치를 다시 정리한다. 필터 추정값의 위치 RMSE는 센서 원시값 20.04 mm에서 4.26 mm로 78.7% 개선되었고, 정상상태 오차 공분산 $P_{ss} = 19.51 \text{ mm}^2$ 는 이산 대수 Riccati 방정식의 해석해와 일치하였다. 정상상태 칼만 게인 $K_{ss} = 0.049$, NIS 95.5%가 $\chi^2(df = 1)$ 95% 신뢰구간 내에 위치하여 필터 일관성이 확인되었다 (4.1.3절 참조). 또한 3.8절의 Python $\leftrightarrow$ C 등가성 검증에서 통합 펌웨어 측정 $P = 19.506 \cdot K = 0.048766$ 이 E0 시뮬레이션 결과와 소수점 셋째 자리까지 일치함을 재확인하였다.

5.1.2 E1 baseline 결과

E1은 흰 우드락 벽 환경에서 측정 노이즈 변동이 없는 정상 조건을 모사한 baseline 시나리오이다. 2차 측정 5 run의 frame 수는 run01부터 run05 순으로 236, 233, 232, 235, 231 frame (총 1,167 frame, 각 약 5초 측정 $\times$ 50 Hz 데시메이션)이며, range_status = 0 비율은 5 run 전체에서 100%로 유지되어 신호 손실이 관찰되지 않았다. 5 run 평균 위치 추정 RMSE는 Raw $7.36 \pm 1.43 \text{ mm}$, Fixed KF $5.41 \pm 1.39 \text{ mm}$, CM-AKF $5.58 \pm 1.39 \text{ mm}$, TinyML-AKF $5.76 \pm 1.42 \text{ mm}$ 로 측정되어 세 KF 알고리즘이 baseline 환경에서 거의 동등한 성능을 보였다 (Fixed 대비 CM +3.1%, TinyML +6.5%). NIS pass rate는 Fixed 0.957, CM 0.965로 두 알고리즘 모두 $\chi^2(df = 1)$ 95% 신뢰구간 내 일관성을 보였다. CM-AKF의 R 추정값은 5 run 평균 13.9 mm^2 로 측정되어 4.1.3절 캘리브레이션 $R_0 = R_{\text{INIT}} = 24 \text{ mm}^2$ 보다 작은 영역에 자리잡았다. TinyML 추론 시간은 5 run 평균 $35.10 \mu\text{s}$ 로 측정되었다.

5.1.3 E2 반사율 변화 결과

E2는 흰 우드락 / 검정 우드락 / 투명 아크릴 세 가지 벽 표면을 측정 노이즈 환경 변화 요인으로 도입한 시나리오이다. 2차 측정 9 run (벽 3종 $\times$ 3 run)의 frame 수는 흰 우드락에서 234, 236, 236(소계 706), 검정 우드락에서 229, 234, 231(소계 694), 투명 아크릴에서 234, 233, 228(소계 695), 총 2,095 frame이었으며, 모든 frame에서 range_status = 0이 유지되어 측정 신호 손실은 관측되지 않았다. 표면별 위치 추정 RMSE는 [표 5-1]과 같다.

[표 5-1] 표면별 위치 추정 RMSE

표면	n	Raw	Fixed KF	CM-AKF	TinyML
흰 우드락	3	12.63 $\pm$ 6.08	9.72 $\pm$ 5.98	5.48$\pm$1.50	6.83 $\pm$ 1.87
검정 우드락	3	12.06 $\pm$ 7.21	8.19 $\pm$ 7.27	4.77$\pm$2.05	6.12 $\pm$ 3.31
투명 아크릴	3	16.14 $\pm$ 1.96	13.77 $\pm$ 3.02	13.08 $\pm$ 4.26	12.87$\pm$3.89

CM-AKF가 흰·검정 우드락 표면에서 가장 낮은 RMSE를 보였으며, 투명 아크릴에서는 CM과 TinyML이 거의 동등하였다 (RMSE 차이 0.21 mm). 전체 구간 평균 cm_R은 흰 130.71, 검정 116.44, 투명 아크릴 127.27 mm² 로 측정되어, 세 표면이 유사한 R 영역에 분포하였다. tof_signal_rate는 흰 20.45, 검정 11.10, 투명 아크릴 13.18 Mcps로 재질별 변별력을 보였다. TinyML R 추정값은 흰 63.86, 검정 62.55, 투명 아크릴 104.22 mm² 로, 투명 아크릴 표면에서만 CM-AKF에 가까운 값으로 추정하였다. 본 시나리오에서 의도하였던 range_status $\neq$ 0 발생은 940 nm IR의 일반 투명 아크릴 부분 투과로 인하여 관측되지 않았다 (5.3.4절).


5.1.4 E3 동적 차단 결과

E3는 알루미늄 판을 ToF 빔 정면에 약 0.75~1초간 동적으로 진입시켜 stuck sensor 패턴을 재현하는 시나리오이다. 시나리오 설계는 초기 계획(검정 우드락 정적 측면 차단)의 사전 시험 결과를 반영하여 현재 형태로 재설계되었으며, 재설계 배경은 5.3.4절 한계 단락에서 기록한다.

2차 측정 5 run의 frame 수는 run01부터 run05 순으로 235, 228, 226, 231, 232 frame(총 1,152 frame, 각 약 5초 측정)이며, 5 run 전체에서 cm_R과 tinyml_R 모두 R 적응 상한 10000 mm² clamp에 도달하여 stuck sensor 패턴의 재현성을 확인하였다. 5 run 위치 추정 RMSE는 Raw

47.46 $\pm$ 12.79 mm, Fixed KF 44.94 $\pm$ 12.41 mm, CM-AKF 14.17 $\pm$ 11.49 mm, TinyML-AKF 16.64 $\pm$ 8.31 mm로 측정되었다. CM-AKF와 TinyML-AKF가 Fixed KF 대비 약 1/3 수준의 RMSE를 달성하여 적응형 R 추정이 동적 outlier 환경에서 효과적임을 정량적으로 입증하였다. CM-AKF의 평균 R 은 5 run에서 1724 ~ 2070 mm² 영역에 분포하였고, TinyML의 평균 R 은 1803 ~ 2287 mm² 영역에 분포하여 두 알고리즘이 유사한 R 영역에 자리잡았다. NIS pass rate는 Fixed 0.874, CM 0.935로 CM이 동적 외란 조건에서도 일관성을 유지하였다.

[그림 5-1]에 run 03을 대표 사례로 한 cm_R 및 tinymL_R의 시계열을 제시하였다. 두 알고리즘 모두 차단 진입 후 약 0.3초 내 R 클램프 상한 10,000 mm²에 도달하였고, 차단 이탈($t \approx 4.3$ 초) 직후 R 이 감소하기 시작하였다. 정량적으로, 차단 이탈 후 R 이 1,000 mm² 이하로 회복되는 시점은 TinyML-AKF가 차단 이탈 후 60 ms(3 frames)인 반면 CM-AKF는 160 ms(8 frames)로, TinyML-AKF가 R 회복 속도 기준 약 2.7배 빠르게 회복하였다. 단 회복 속도 차이는 본 시나리오의 짧은 외란 구간(평균 약 1초)에서는 위치 추정 RMSE로 누적되지 않았다 (5.2.2절 (b) 및 5.4.6절 참조).



[그림 5-1] CM-AKF와 TinyML-AKF의 R 동역학 비교 (E3 run03)

5.1.5 E4 정적 안정성 결과 – RQ1

E4는 흰 우드락 벽 환경에서 로봇을 정지 상태로 30분 $\times$ 3 run 측정한 시나리오이다. 3 run 모두 360,000 loops (30분 $\times$ 200 Hz)를 무중단 완주하였으며, body overrun 및 ISR overrun 0회로 측정되었다. PC 측에 수신·기록된 frame 수는 run01부터 run03 순으로 83,865, 83,727, 83,830 frame(총 251,422 frame)이었으며, 50 Hz 테시메이션 기준 예상 frame 수 90,000 대비 약 93% 도달율로, HC-06 무선 구간에서 약 7%의 frame 손실이 관측되었다. 손실 frame의 시간 위치는 seq 필드를 통해 식별 가능하므로 분석 정합성에는 영향이 없다 (5.3.5절).

TinyML 추론 시간은 누적 242,992회 측정에서 mean 35.32 μ s, max 38.10 μ s, run-to-run std 0.007 μ s로 입력 무관 결정론적 동작이 확인되었다.

메인 루프 시간은 3 run 모두 mean 1.24 ms, max 3.58 ms로 측정되어 4.5 ms overrun 마진 내 안정 운용이 확인되었다.

위치 추정 RMSE는 Raw 5.14 $\pm$ 0.04 mm, Fixed KF 1.87 $\pm$ 0.12 mm, CM-AKF 1.86 $\pm$ 0.13 mm, TinyML-AKF 1.93 $\pm$ 0.11 mm로 세 KF 알고리즘이 모두 Raw 대비 약 63% 개선되었으며, 알고리즘 간 차이는 0.07 mm 이내로 정적 조건에서 거의 동등한 동작을 보였다. CM-AKF의 R 추정값은 3 run에서 mean 22.84 / 23.08 / 22.98 mm² (run-to-run 표준편차 0.121, CV 0.53%)로 측정되어 장기 안정성이 확인되었다. HC-06 무선 무결성은 3 run 평균 약 96% (펌웨어 측 송신 drops = 0)로 측정되었으며, seq 필드를 통한 시간축 재구성으로 분석 적합성을 유지하였다.

5.1.6 E5 일반화 결과

E5는 학습 데이터에 포함되지 않은 회색 단면 우드락 벽 환경에서 TinyML-AKF의 일반화 능력을 검증한 시나리오이다. 5 run의 frame 수는 run01부터 run05 순으로 192, 190, 195, 193, 194 frame(총 964 frame, 각 약 5.0초 측정)이었다. 5 run 통합 결과 9개 하드웨어/펌웨어 검증 항목 전부 통과하였다.

위치 추정 RMSE는 Raw 8.40 $\pm$ 3.20 mm, Fixed KF 6.18 $\pm$ 2.94 mm, CM-AKF 5.09 $\pm$ 2.77 mm, TinyML-AKF 5.62 $\pm$ 2.52 mm로 측정되어, 미지 표면 환경에서도 두 적응형 알고리즘이 Fixed KF 대비 우위를 보였다. NIS pass rate는 Fixed 0.928, CM 0.961로 일관성이 유지되었다. TinyML-AKF의 R 추정값은 5 run 통합 mean 24.78 mm² 로 R 클램프 한계(1.0 / 10000.0 mm²)에 도달하지 않았으며, CM-AKF의 R mean 35.04 mm² 와 유사한 영역에 자리잡았다.

특기할 점으로, Run 5에서 cm_R_max가 489.5 mm² 로 다른 4 run(58~66 mm²) 대비 약 8배 높게 측정되었고, 동시에 tof_signal_rate 평균이 20.2 Mcps로 다른 run(12.6~19.7 Mcps)의 상단을 넘는 수준이었다. 그럼에도 위치 추정 RMSE는 Run 5에서 CM 2.97, TinyML 5.10으로 정상 범위에서 측정되어, 폭증이 위치 추정 발산으로 이어지지 않았다. tof_signal_rate는 5 run 평균 16.3 Mcps로, 흰 우드락의 E1(18.1 Mcps) 대비 다소 낮은 수준으로 측정되었다 (Run 5 제외 시 평균 15.3 Mcps).

5.1.7 시나리오별 평가 지표 종합

본 5.1절에서 시나리오별로 보고한 측정 결과를 [표 5-2]에 통합하여 정리한다. [표 4-5]에 정의된 평가 지표 중 RMSE, MAE, NIS pass rate, 정상상태 RMSE(RMSEss), 수렴 시간(Tconv)

다섯 가지를 시나리오별로 정리한다. R 거동 분석 결과는 5.2절 RQ별 논의에서 다루며, TinyML 추론 시간은 5.1.5절(E4)에서 별도 보고한다.

[표 5-2] 시나리오별 평가 지표 종합 (mean $\pm$ std)

시나리오	n (frame/run)	알고리 즘	RMSE (mm)	MAE (mm)	NIS pass	RMSEss (mm)	Tconv (ms)
E1 (5 run, total 1,167)	231~236	Raw	7.36 $\pm$ 1.43	5.80 $\pm$ 1.12	—	—	—
		Fixed KF	5.41 $\pm$ 1.39	4.22 $\pm$ 1.03	0.957	2.15 $\pm$ 1.52	3,016 $\pm$ 1,848
		CM-AKF	5.58 $\pm$ 1.39	4.37 $\pm$ 1.03	0.965	2.38 $\pm$ 1.44	2,300 $\pm$ 1,785
		TinyML- AKF	5.76 $\pm$ 1.42	4.51 $\pm$ 1.05	—	2.35 $\pm$ 1.47	2,320 $\pm$ 1,767
E2 white (3 run, total 706)	234~236	Raw	12.63 $\pm$ 6.08	9.08 $\pm$ 3.51	—	—	—
		Fixed KF	9.72 $\pm$ 5.98	6.96 $\pm$ 3.47	0.949	1.73 $\pm$ 0.75	3,273 $\pm$ 1,978
		CM-AKF	5.48 $\pm$ 1.50	4.38 $\pm$ 0.90	0.964	1.97 $\pm$ 0.68	3,213 $\pm$ 1,929
		TinyML- AKF	6.83 $\pm$ 1.87	5.25 $\pm$ 1.12	—	1.93 $\pm$ 0.66	3,213 $\pm$ 1,927
E2 black (3 run, total 694)	229~234	Raw	12.06 $\pm$ 7.21	8.64 $\pm$ 5.01	—	—	—
		Fixed KF	8.19 $\pm$ 7.27	5.96 $\pm$ 4.84	0.854	2.73 $\pm$ 1.22	2,940 $\pm$

							1,775
		CM-AKF	4.77 ± 2.05	3.80 ± 1.52	0.944	2.82 ± 1.05	2,893 ± 231
		TinyML-AKF	6.12 ± 3.31	4.67 ± 2.26	—	2.85 ± 1.09	3,013 ± 1,585
E2 acryl (3 run, total 695)	228~234	Raw	16.14 ± 1.96	12.08 ± 1.88	—	—	—
		Fixed KF	13.77 ± 3.02	10.99 ± 2.23	0.779	4.41 ± 0.69	4,593 ± 31
		CM-AKF	13.08 ± 4.26	10.92 ± 3.51	0.934	6.42 ± 4.34	2,213 ± 2,102
		TinyML-AKF	12.87 ± 3.89	10.69 ± 2.98	—	5.32 ± 2.56	3,533 ± 1,900
E3 (5 run, total 1,152)	226~235	Raw	47.46 ± 12.79	26.78 ± 5.63	—	—	—
		Fixed KF	44.94 ± 12.41	25.24 ± 5.45	0.874	24.54 ± 28.93	1,000 ± 0
		CM-AKF	14.17 ± 11.49	11.29 ± 8.86	0.935	17.32 ± 20.84	1,000 ± 0
		TinyML-AKF	16.64 ± 8.31	12.82 ± 6.83	—	16.96 ± 17.00	1,080 ± 179
E4 (3 run, total 251,422)	83,727~83,865	Raw	5.14 ± 0.04	4.10 ± 0.03	—	—	—
		Fixed KF	1.87 ± 0.12	1.49 ± 0.11	0.953	—	—

		CM-AKF	1.86 ± 0.13	1.48 ± 0.12	0.955	—	—
		TinyML-AKF	1.93 ± 0.11	1.54 ± 0.10	—	—	—
E5 (5 run, total 964)	190~195	Raw	8.40 ± 3.20	6.38 ± 2.20	—	—	—
		Fixed KF	6.18 ± 2.94	4.59 ± 1.95	0.928	1.36 ± 0.44	3,692 ± 110
		CM-AKF	5.09 ± 2.77	3.92 ± 1.96	0.961	1.63 ± 0.40	3,652 ± 111
		TinyML-AKF	5.62 ± 2.52	4.24 ± 1.76	—	1.57 ± 0.44	3,664 ± 111

5.2 연구 질문과 discussion

5.2.1 RQ1 – 실시간 동작 가능성

RQ1: STM32F446RE MCU 환경에서 TinyML 기반 측정 노이즈 공분산 R 추정치 200 Hz 제어 루프의 시간 제약 내에서 실시간 동작 가능한가?

답: 가능함을 정량적으로 입증하였다.

E4 정적 안정성 시나리오 3 run × 30분 누적 측정에서 다음 네 가지 지표로 RQ1 답변을 구성한다. 첫째, TinyML 추론 시간은 mean 35.32 μ s로 TinyML 추론 목표 시간 500 μ s의 7.1% (14배 안전 마진), max 38.10 μ s로 목표 시간의 7.6%에서 동작하였다. 이는 200 Hz 제어 루프 예산 5 ms 기준으로는 각각 0.71%, 0.76% 수준이다. 둘째, 추론 시간 표준편차는 242,992회 누적 측정에서 0.007 μ s로, 입력 데이터와 무관한 결정론적 동작이 확인되었다. INT8 양자화 모델이 정수 연산만 수행하므로(3.8.3절 참조), 추론 시간이 입력값에 따라 변동하지 않는다. 셋째, 메인 루프 시간은 mean 1.24 ms로 200 Hz 예산 5 ms의 27.5%, max 3.58 ms로 4.5 ms overrun 마진 내에서 동작하였다. 넷째, 누적 360,000 loops × 3 run에서 body overrun 및 ISR overrun이 모두 0회로, 실시간 제약 위반이 발생하지 않았다.

본 결과는 200 Hz 제어 루프 안에서 TinyML 추론과 KF 갱신이 메인 루프 시간 제약(< 5 ms) 내 안정적으로 완료됨을 의미한다. 추론 시간이 TinyML 추론 목표 시간 500 μ s의 약 7%

수준(200 Hz 제어 루프 예산 5 ms 기준 약 0.7%)에 머문 점은, 향후 더 큰 입력 차원(>6 feature)이나 더 깊은 모델 구조의 도입을 검토할 여지를 제공한다.

5.2.2 RQ2 – 측정 노이즈 적응성

RQ2: TinyML-AKF는 CM-AKF 대비, 복합 노이즈가 존재하는 시나리오(E2, E3, E5)에서 위치 추정 정확도와 R 추정 거동 측면에서 어떠한 차이를 보이는가?

답: TinyML-AKF는 R 추정 거동, 특히 외란 회복 속도에서 CM-AKF를 앞선다. 차단 이탈 후 R 회복이 CM-AKF 대비 약 2.7배 빠르며, 이는 잔차 단일 통계로는 불가능한 거동이다. 정상 변동 환경의 위치 RMSE는 두 알고리즘이 동등 수준이고, 둘 다 Fixed KF 대비 전 시나리오 우위를 보인다.

(a) 정상 변동 환경 – E2 반사율 변화

E2 9 run에서 표면별 위치 RMSE는 흰 우드락에서 CM 5.48 mm vs TinyML 6.83 mm, 검정 우드락에서 CM 4.77 mm vs TinyML 6.12 mm, 투명 아크릴에서 CM 13.08 mm vs TinyML 12.87 mm로 측정되어, CM-AKF가 두 우드락 표면에서 1~1.4 mm 낮은 RMSE를 보였고, 투명 아크릴에서는 두 알고리즘이 거의 동등하였다. CM-AKF는 잔차 분산이라는 단일 통계만으로 표면별 노이즈 환경에 빠르게 적응하여, 정상 변동 환경에서 강력한 baseline임을 정량적으로 입증하였다. TinyML-AKF의 R 추정값은 CM-AKF 대비 약 50~80% 수준으로 작게 추정되어, 이로 인해 칼만 게인이 측정 쪽으로 더 치우치며 측정 노이즈를 더 많이 흡수하게 된다. 이는 정상 변동 환경에서 TinyML-AKF가 CM-AKF 대비 위치 추정 우위를 갖지 않는 구조적 원인이다.

수렴 시간(T_{conv}) 관점에서도 유사한 패턴이 관찰된다. 흰·검정 우드락에서는 세 알고리즘 모두 2.9~3.3초 수준으로 큰 차이를 보이지 않았으나, 투명 아크릴에서 Fixed KF는 $4,593 \pm 31$ ms로 측정 종료 시점까지도 정상상태에 거의 도달하지 못한 반면 CM-AKF는 $2,213 \pm 2,102$ ms로 약 절반 시간 내 수렴하였다. 본 결과는 R 적응이 노이즈가 큰 표면에서 수렴 속도 측면에서도 이점을 가짐을 보인다.

NIS pass rate 결과는 CM-AKF의 적응성을 추가로 뒷받침한다. Fixed KF의 NIS pass rate는 흰 우드락(0.949)에서 검정 우드락(0.854), 투명 아크릴(0.779)로 표면 변화에 따라 점진적으로 감소하여 $\chi^2(df=1)$ 95% 신뢰구간 일관성을 위반한 반면, CM-AKF는 세 표면 모두 0.93 이상(0.964 / 0.944 / 0.934)을 유지하였다. Fixed KF의 일관성 저하는 R 고정값이 변화된 표면별 노이즈 환경과 부합하지 않음을 의미하며, CM-AKF는 R 적응을 통해 필터 일관성을 보존한다. 본 결과는 정상 변동 환경에서 R 적응 메커니즘 자체의 가치를 정량적으로 입증한다.

(b) 동적 outlier - E3 알루미늄 차단

E3는 5.1.4절에서 기술한 바와 같이 2.2.3절에서 합성 데이터로 보고된 CM-AKF의 stuck sensor 한계가 실물 환경에서 재현된 시나리오이다. 그러나 위치 추정 RMSE 기준으로는 CM-AKF 14.17 mm와 TinyML-AKF 16.64 mm가 Fixed KF 44.94 mm 대비 약 1/3 수준의 RMSE를 달성하여, R 적응 메커니즘 자체가 동적 outlier 환경에서 효과적임을 확인하였다. CM-AKF가 R 을 10000 mm² 클램프까지 키워 측정값을 강하게 불신하는 동안 칼만 필터가 prediction에 의존하여 위치 추정을 유지하는 구조가 작동한 것으로 해석된다.

TinyML-AKF가 CM-AKF 대비 RMSE 우위를 보이지 않은 점은, 본 시나리오에서 외란 종료 후 R 추정값의 빠른 회복이 위치 추정 RMSE에 결정적이지 않았음을 시사한다. 외란 구간이 평균 약 1초 내외로 짧고, 외란 직후 위치 변화도 작은 본 실험 조건에서는 R 회복 속도의 차이가 위치 RMSE에 누적되기 전에 측정 구간이 종료되었다. TinyML R 의 빠른 회복 패턴(5.2.3절 (a))은 R 적응 거동의 다변량 feature 활용 증거로서 의의가 있으며, 더 긴 외란 또는 연속된 외란이 반복되는 시나리오에서는 위치 RMSE에도 영향을 미칠 가능성이 있다 (5.4절).

수렴 시간(T_{conv})은 세 알고리즘 모두 1,000 ms 수준으로 측정되었으나, 본 시나리오는 시동 후 외란이 발생하는 구조이므로 T_{conv} 는 외란 회복 시간을 반영하지 않는다 (외란 후 R 회복 동역학은 [그림 5-1] 및 본 절 앞 단락에서 분석).

(c) 미지 표면 일반화 - E5 회색 우드락

E5에서 위치 RMSE는 CM-AKF 5.09 mm, TinyML-AKF 5.62 mm로 두 알고리즘이 거의 동등하였으며, 둘 다 Fixed KF 6.18 mm 대비 우위를 보였다. TinyML R 은 [1.74, 321.26] mm² 범위에서 R 클램프 한계에 도달하지 않고 산출되었으며, CM-AKF R 분포와 유사한 영역에 자리잡았다. 본 결과는 TinyML 모델이 학습 분포(흰/검정 우드락 + 투명 아크릴) 외의 표면 조건에서도 발산 없이 일반화됨을 시사한다.

본 항의 메인 6-feature 모델 hold-out 평가 결과는 [표 5-2]의 TinyML-AKF 행을 통해 시나리오별로 확인할 수 있다. 6-feature 모델은 E1 · E2 · E3 · E5 hold-out 데이터(각 시나리오 Run 4-5 또는 벽별 Run 3, E5 전량)에서 위치 추정 RMSE 5.62 ~ 16.64 mm 수준으로 작동하였다. 3-feature ablation 모델(F1 · F2 · F3, INT8 양자화 209 파라미터, 3.16 KB)의 위치 추정 성능을 1차 측정 hold-out 데이터셋(E2 white/black/acryl run03, E3 run04 · run05, 총 1,165 frame)에서 PC 사후 추론으로 평가하였다. 평가 방식은 각 frame에서 3-feature 모델이 추론한 R 을 참조 1D KF에 주입하여 위치를 재추정하는 방식이며, 비교 기준으로 동일 데이터셋의 펌웨어 라이브 cm_estimate 및 fixed_estimate를 사용하였다.

본 ablation은 1차 측정 데이터를 대상으로 하며, 4.1.2절에서 채택한 ToF anchor 기반 GT 대신 단순 엔코더 누적 GT(기준거리 500 mm - encoder 누적 거리)를 적용하여 산출하였다. 이는 1차 측정 데이터에 ToF anchor 보간에 필요한 시작·종료 구간 정보가 일관되게 확보되지 않았기 때문이며, 이로 인해 본 표의 절대 RMSE는 ToF anchor GT를 적용한 [표 5-2]의 2차 측정 결과보다 전반적으로 크게 측정된다. 따라서 본 표는 절대값이 아닌 모델 간 상대 비교에 한정하여 해석한다.

[표 5-3]에 시나리오별 hold-out 위치 RMSE를 정리하였다. 정상 변동 환경(E2 흰 우드락, 검정 우드락)에서 3-feature 모델은 위치 RMSE 기준 CM-AKF와 유사한 수준(white 31.77 vs CM 32.99, black 38.63 vs CM 43.54)으로 동작하였다. 그러나 동일 정상 변동 환경 중 E2 투명 아크릴 run03에서는 3-feature 모델의 위치 RMSE가 97.00 mm로 측정되어 CM-AKF (32.86 mm) 대비 +64.14 mm 열위 및 발산 패턴(표 5-3의 * 표시)이 관측되었다. 흰·검정 우드락이 학습 분포에 포함된 반면, 투명 아크릴은 940 nm IR 부분 투과 특성으로 잔차 통계만으로는 노이즈 특성을 충분히 식별하기 어려운 표면임에도 학습 데이터에 포함되어 있어, 잔차 통계 외 정보($F4 \cdot F6$)의 보완 없이는 본 환경에서 KF 패루프 안정성이 확보되지 않음을 보인다. 본 결과는 정상 변동 환경에서 잔차 통계 3개만으로도 R 추정과 위치 추정이 CM-AKF에 근접한 성능을 달성할 수 있음을 보인다. 이는 5.2.3 (c) 앞 단락에서 기술한 $F2 \approx R + P$ 관계(E1 baseline 분석)와 일치하는 결과이며, 정상 주행 시 잔차 통계가 R 의 충분 통계에 해당함을 실측 데이터로 확인한 것이다.

반면 동적 outlier 환경(E3 알루미늄 차단)에서는 3-feature 모델이 CM-AKF 대비 명확한 열위를 보였다. 본 비교는 1차 측정 hold-out 데이터(run04·run05)에 엔코더 누적 GT를 적용한 값으로, 2차 측정 5 run 전체에 ToF anchor GT를 적용한 5.1.4절의 CM-AKF RMSE(14.17 mm)와는 측정 차수·GT 정의가 다르다. 1차 hold-out 기준 E3 run04에서 위치 RMSE는 CM-AKF 17.47 mm 대비 3-feature 47.17 mm로 약 2.7배, run05에서 CM-AKF 18.27 mm 대비 3-feature 30.79 mm로 약 1.7배 높게 측정되었다.

3-feature 모델은 stuck sensor 구간에서 R 클램프 한계($10,000 \text{ mm}^2$)에 도달하기는 하였으나(E3 run04에서 CM-AKF 12 frame vs 3-feature 15 frame 도달), R 추정의 시간 동역학이 CM-AKF와 미세하게 어긋나 위치 추정 RMSE에 누적되는 결과를 보였다. 동일한 stuck sensor 환경에서 CM-AKF가 우위를 보인 것은, 펄웨어 라이브 cm_R이 학습 라벨 자기 자신이라는 점에서 self-reference 우위가 일부 작용한 것으로 해석된다. 동시에, 잔차 통계만으로는 stuck sensor 구간의 R 적응 동역학을 학습 라벨 수준으로 충실히 재현하기 어려움을 시사한다.

본 ablation 결과는 (i) 정상 변동 환경 중 학습 분포 내 표면(E2 흰/검정

우드락)에서는 잔차 통계 3개로도 충분한 R 적응이 가능하다는 점, (ii) 동적 outlier 환경(E3 알루미늄 차단) 및 광학적 특이 표면(E2 투명 아크릴)에서는 잔차 통계 외 feature(F4 sensor_disagreement, F6 signal_rate)의 보완이 필요하다는 점을 정량적으로 보여준다. 후자는 5.2.3 (a)에서 그림 5-2로 입증한 F6의 선행 지표 특성과 일관되며, RQ3에서 제기한 다변량 feature 활용의 정당성이 위치 추정 RMSE 수준에서도 시나리오 의존적으로 확인됨을 의미한다. 다만 본 ablation의 절대 RMSE 값은 1차 측정 데이터의 ground truth 산출 오차(wheel slip 등)로 인해 표 5-2의 2차 측정 결과 대비 시나리오 전반에 걸쳐 큰 값으로 측정되므로, 두 모델 간의 상대적 비교에 한해 해석한다.

[표 5-3] 3-feature ablation 모델의 hold-out 위치 RMSE 비교 (1차 측정 데이터셋)

시나리오	n (frame)	Fixed KF (mm)	CM-AKF (mm)	3-feature TinyML (mm)	3-feat vs CM
E2 white run03	230	32.51	32.99	31.77	-1.22 mm
E2 black run03	239	42.16	43.54	38.63	-4.91 mm
E2 acryl run03	236	36.85	32.86	97.00*	+64.14 mm
E3 run04	226	53.83	17.47	47.17	+29.70 mm
E3 run05	234	44.80	18.27	30.79	+12.52 mm
frame 가중 평균	1,165	42.59	30.80	55.08**	+24.28 mm

*: E2 acryl 시나리오는 R 값이 큰 영역(평균 426 mm^2 , 최대 $2,501 \text{ mm}^2$)에서 동작하여 1차 측정 데이터의 KF 재실행 시 ground truth 산출 오차가 증폭된 결과이며, 두 모델 간의 상대 비교에는 영향이 적은 것으로 해석한다.

**: PC 사후추론 시 위치 추정 발산 또는 R 클램프 상한 지속 도달 구간 포함 (frame 가중 평균에 영향)

종합 정성 결론: 위치 RMSE 기준으로 CM-AKF가 모든 시나리오에서 TinyML-AKF와 동등하거나 1~1.4 mm 낮은 수준을 보였으나, 두 적응형 알고리즘 모두 Fixed KF 대비 분명한 우위를 보였다 (E3에서 약 1/3, E2 우드락 표면에서 약 1/2 ~ 2/3 수준의 RMSE). TinyML-AKF의 차별성은 5.2.3절 RQ3 논의에서 다루는 R 추정 거동의 다변량 feature 활용에서 관찰되며, 위치

추정 RMSE보다 R 거동 분석이 본 알고리즘 차이를 드러내는 적합한 지표임을 본 결과가 시사한다.

5.2.3 RQ3 – 다변량 feature 활용의 정당성

RQ3: TinyML 모델이 사용하는 6개 feature 중 잔차 통계 외 feature(sensor disagreement, signal rate 등)가 R 추정에 실제로 기여하는가?

답: 기여한다. 정상 주행에서는 잔차 분산이 R 을 충분히 근사하지만($F2 \approx R$), 동적 outlier(E3)와 광학적 특이 표면(E2 투명 아크릴)에서는 이 근사가 깨진다. signal_rate(F6) · sensor_disagreement(F4)가 잔차 통계로는 얻을 수 없는 정보를 제공하며, 다변량 feature의 정당성이 실측으로 확인된다.

(a) 시간 동역학 차이 – E3


E3 차단 이탈 후 TinyML R 의 점진 감소 패턴은 잔차 단일 통계만으로 산출할 수 없는 거동이다. 잔차 r 은 차단 이탈과 동시에 작은 값으로 회복되지만, 잔차 분산($F2$)이 sliding window 안에서 점진적으로 감소하는 시간 구조를 가지므로 CM-AKF의 R 은 한동안 큰 값을 유지한다. 반면 TinyML이 R 을 CM-AKF보다 빠르게 줄이는 것은 $F4$ (sensor_disagreement) 또는 $F6$ (signal_rate)와 같이 잔차 분산보다 시간적으로 빠르게 회복되는 feature가 추론에 반영되었음을 시사한다. 본 거동 차이는 위치 추정 RMSE에는 본 실험 조건에서 결정적으로 나타나지 않았으나 (5.2.2절 (b)), R 추정 자체의 적응성 측면에서는 다변량 feature 활용의 직접 증거이다.

[그림 5-2]는 E3 run03의 차단 진입·이탈 구간에서 TinyML 입력 feature 중 $F1$ (residual), $F4$ (sensor_disagreement), $F6$ (tof_signal_rate) 세 채널의 시계열을 비교한 결과이다. 가장 주목할 점은 $F6$ signal_rate가 다른 feature들보다 먼저 변화 신호를 보인다는 것이다. $F6$ 는 차단 진입 직전($t \approx 2.8$ 초)부터 baseline의 $\pm 3\sigma$ 를 벗어나 증가하기 시작하며, 차단 구간 중반에 약 60 Mcps의 peak에 도달한다. $F1$ residual은 차단 진입 직전에는 baseline 범위 안에 있다가 차단 진입 시점($t \approx 3.0$ 초)에 비로소 큰 변화를 보이며, $F4$ sensor_disagreement는 차단 진입 직전과 중반에 두 차례 peak를 보인다.

정량 분석 결과, 차단 진입 시점(TinyML R 의 clamp 도달 frame)을 기준으로 $F6$ 는 baseline $\pm 3\sigma$ 를 벗어나는 첫 변화가 4 frame (80 ms) 먼저 발생하였으며, $F1$ 및 $F4$ 는 차단 진입 시점 이전에 baseline $\pm 3\sigma$ 임계를 벗어나지 않았다.

이는 $F6$ signal_rate가 잔차 통계가 반응하기 이전에 먼저 변화하는 선행 지표(leading indicator)라는 3.5.3절의 가설을 본 실측 데이터로 뒷받침하는 결과이다.

차단 이탈 후 회복 단계에서는 F1·F4·F6 모두 거의 동시(차단 이탈 frame 0~3 frame 이내)에 baseline 범위로 복귀하였으며, 이로부터 두 적응형 알고리즘이 정상값 영역으로 R을 회복하는 동역학에 다변량 feature가 기여한 것으로 해석된다.



[그림 5-2] F6 signal_rate의 선행 변화 — F1·F4·F6 시계열 비교 (E3 run03)

(b) signal_rate와 표면 가시광 반사율의 불일치 - E2 투명 아크릴

E2에서 측정된 표면별 signal_rate(흰 우드락 20.5 / 검정 우드락 11.1 / 투명 아크릴 13.2 Mcps)는, ToF 센서의 신호 강도가 표면의 가시광 반사율과 단순한 단조 관계에 있지 않음을 보여준다. 가시광 기준 거의 투명하여 반사가 가장 약할 것으로 예상되는 투명 아크릴이 가시광 흡수체인 검정 우드락보다 오히려 높은 signal_rate를 보였으며, 이는 signal_rate가 시각적 밝기가 아니라 표면의 940 nm IR 정반사 · 투과 특성에 의해 결정되기 때문이다. 사람이 직관으로 "밝은 표면일수록 signal_rate가 높을 것"이라는 규칙을 만들 수 없는 영역이며, 이는 다변량 학습 기반 R 추정 접근의 정당성을 뒷받침한다.

(c) Ablation - 6-feature vs 3-feature

E1 baseline 데이터의 분석에서, F2 (cm_residual_var)가 R 라벨(cm_R)과 강한 선형

상관을 가짐이 확인되었다. 정상 주행 시 잔차 평균이 0에 근접하여 $Var(r) \approx E[r^2]$ 가 성립하고, KF 이론상 $E[r^2] = P + R$ 이므로 $F2 \approx R + P$ 관계가 성립한다. 실측 $|F2 - R_label|$ 은 정상상태 구간(측정 후반 100 frame)에서 mean 2.3 mm^2 , max 3.4 mm^2 로 $P_{ss}(\approx 19.51 \text{ mm}^2)$ 보다 작은 수준에 머물러, 정상 주행 시 F2가 R 라벨을 잘 근사함을 보였다. 반면 수렴 과도 구간을 포함한 전체 주행에서는 mean 4.2 mm^2 , max 약 32 mm^2 로 차이가 크게 확대되어, 이 근사 관계가 정상상태에 한정하여 성립함이 확인되었다. 본 관계는 E1 baseline에서 3-feature(F1-F3) 모델이 6-feature 모델 대비 우위가 작게 나올 수 있는 구조적 근거를 제공하는 한편, 동적 outlier·미지 표면 환경과 같이 잔차 평균이 0에서 벗어나 근사가 깨지는 구간에서는 F4·F6 등 추가 feature의 기여가 명확히 드러날 것임을 시사한다.

표 4-10에 보고한 ablation 결과에 따르면, 6-feature 모델은 절대 오차(MAE_R f32) 357.31 mm^2 로 3-feature 모델 387.72 mm^2 대비 30.41 mm^2 작았으나, 비례 오차(MAPE_R) 기준 6-feature 34.3% vs 3-feature 20.1%로 3-feature가 우세하였으나, INT8 양자화 후 MAE_R은 6-feature가 273.13 mm^2 로 3-feature 393.94 mm^2 보다 낮아 절대 오차 기준으로는 6-feature가 우세함이 확인되었다. F5가 학습 데이터 전 구간에서 상수 입력으로 작용하였으므로(3.5.2절 후단), 본 ablation은 실질적으로 F4·F6 추가의 가치를 측정한 것이며, 본 학습 데이터 분포에서 multi-modal feature의 R 정확도 우위는 제한적인 것으로 평가된다. 위치 추정 RMSE 기준의 ablation 비교는 5.2.2 (c) [표 5-3]에서 1차 측정 hold-out 데이터셋(N=1,165 frame)으로 별도 수행하였으며, 정상 표면(E2 흰·검정 우드락)에서 잔차 통계 3개의 충분 통계 가설을 지지하는 한편 동적 outlier(E3) 및 광학적 특이 표면(E2 투명 아크릴)에서 F4·F6 보완의 필요성을 정량적으로 확인하였다.

(d) F5 데이터 한계 - 모델 한계가 아닌 데이터 한계

본 실험 환경의 E1·E2·E3·E5 전체 24 run에서 range_status $\neq 0$ 이 발생하지 않아, F5 (Measurement Rate)는 모든 frame에서 1.0 상수로 측정되었다. 본 학습 데이터 환경에서 F5는 사실상 정보가 없는 입력으로 작용하며, ablation에서 6-feature와 5-feature(F5 제외) 모델 간 차이가 작게 나타날 가능성이 있다. 이는 모델의 한계가 아닌 학습 데이터 환경의 한계이며, F5를 입력 채널에서 제거하지 않고 더 극단적인 신호 손실 환경에 대비한 예비 채널(reserve channel)로 유지하는 본 연구의 설계(3.5.3절)와 일치한다.

5.3 한계

본 절에서는 본 연구의 한계를 정직하게 기록한다. 5.4절 향후 연구 방향과 연결된다.

5.3.1 학습 데이터의 환경 다양성 한계

본 연구의 학습 데이터는 단일 거리(500 mm), 단일 조명(직사광선 차단 실내), 단일 작업자, 학습 표면 3종(흰/검정 우드락 + 투명 아크릴)으로 한정되며, 미지 표면 일반화는 회색 단면 우드락 1종(E5)에서 검증하였다. 본 환경 다양성은 학위 연구 일정과 실험 가능 범위 내에서 결정된 것이며, 실용적 운용 환경에서의 일반화 보장을 위해서는 다거리 · 다조명 · 다재질로의 확장이 필요하다.

5.3.2 F5 변별력의 데이터 한계

5.2.3절 (d)에서 기술한 바와 같이, 본 학습 · 평가 환경의 24 run 전체에서 `range_status` $\neq 0$ 이 발생하지 않아 F5는 상수 입력으로 작용하였다. 본 연구는 F5를 입력 채널에서 제거하지 않고 예비 채널로 유지하는 설계를 채택하였으나, 본 환경에서 F5의 변별력 자체를 정량적으로 검증할 수 없었다. 더 극단적인 신호 손실 환경(센서 물리적 가림, 강한 IR 간섭원 동시 동작 등)이 향후 검증 대상이다.

5.3.3 동적 차단 시나리오의 재현성 한계

E3 동적 ToF 외란은 작업자가 알루미늄 판을 ToF 빔 정면에 손으로 진입시키는 방식으로 수행하였다. 본 방식은 측정 결과 차단 구간 길이가 691~1455 ms (목표 750 ms 기준 $-8\% \sim +72\%$), 차단 진입 위치가 encoder 213~273 mm (목표 250 mm 기준 ± 37 mm)로 변동하였다. 본 연구는 단일 작업자, 사전 매뉴얼 합의, encoder distance 기준 차단 구간 식별의 세 가지 방식으로 변동성을 통제하였다. 향후 자동 차단 장치의 도입으로 재현성을 향상시킬 여지가 있다.

5.3.4 VL53L0X IR 반사/투과 가정의 한계

본 연구의 시나리오 설계는 표면의 가시광 반사율로부터 940 nm IR 반사율을 추정하는 두 가지 가정에 기반하였으나, 실측 단계에서 두 가정 모두 부분적으로만 성립함을 발견하였다.

첫째, E2 투명 아크릴은 ToF 빔에 대한 차단을 통해 `range_status` $\neq 0$ 을 발생시키기 위한 표면으로 의도되었으나, 940 nm IR이 일반 투명 아크릴에 부분 투과적이어서 비정상 status가 9 run 통틀어 0회 관측되었다. 둘째, E3의 초기 설계는 검정 우드락 150×150 mm 판을 ToF 광축 측면에 고정하여 정적 차단을 의도하였으나, 사전 시험 5회에서 비정상 status가 발생하지 않아 알루미늄 판을 ToF 빔 정면에 동적으로 진입시키는 방식으로 메커니즘을 전면 재설계하였다. 두 사례 모두 검정 우드락이 가시광 흡수재이지만 940 nm IR 영역에서는 약 50% 수준의 반사율을 가진다는 점, 그리고 가시광상 거의 투명한 투명 아크릴의 `signal_rate`(13.2

Mcps)가 검정 우드락(11.1 Mcps)보다 높게 측정된 점(E2)과 함께, 가시광 반사율 직관이 ToF 센서의 noise 환경 예측에 그대로 적용되기 어렵다는 발견을 구성한다.

본 발견은 시뮬레이션 가정의 한계를 실측 단계에서 발견하고 시나리오를 정직하게 재설계한 hardware-in-the-loop 검증의 사례로 기록한다.

5.3.5 HC-06 무선 무결성 한계

E4 30분 연속 측정에서 HC-06 무선 구간의 프레임 도달율은 약 93% 수준으로 측정되었다(5.1.5절). 펌웨어 측 DMA TX는 run당 90,000 프레임을 0 drop으로 송신 완료하였으며, 손실은 HC-06 모듈 출력 이후 무선 구간에서 발생하였다. 본 연구는 seq 필드를 통한 시간축 재구성으로 분석 적합성을 유지하였으며, 3 run의 CM-AKF R 평균 CV가 0.53%로 유지된 점에서 본 손실이 RMSE · R 분석에 영향을 미치지 않음을 확인하였다(5.1.5절). 본 한계는 무선 모듈의 장시간 송신 특성으로 평가하며, 향후 더 견고한 무선 프로토콜의 채택이 필요하다.

5.3.6 단일 거리 운용 조건

본 연구의 E1~E5 시나리오는 모두 시작점-벽 500 mm 단일 거리에서 측정되었다. 4.1.3절의 R_0 캘리브레이션도 500 mm 동적 조건에서 결정되었다. 실제 주차 진입 시나리오에서는 거리에 따라 ToF 노이즈 특성이 변화하므로, 거리별 R 변동의 학습이 향후 과제이다.

5.3.7 GT 산정 방식의 한계

본 연구는 수동 굴림 환경의 바퀴 슬립으로 인해 엔코더 단독 누적 거리를 절대 위치 GT로 사용하기 어려움을 실측 단계에서 확인하였다. 전체 측정 run에서 엔코더 누적 이동량은 ToF 양 끝점 기준 실제 이동 거리의 약 75~94% 수준에 그쳤다. 이에 ToF 양 끝점을 거리 anchor로 두고 엔코더를 구간 보간 변수로만 사용하는 방식으로 GT를 산정하였으나(4.1.2절), 이 방식은 ToF 측정 자체의 시작·종료 시점 노이즈에 의존하므로, 향후 외부 고정밀 위치 측정 장비(레이저 거리계, 모션 캡처 등)를 통한 독립 GT 확보가 필요하다.

5.4 향후 연구 방향

본 절에서는 5.3절에 기술한 한계를 향후 연구 과제로 전환한다.

5.4.1 학습 데이터 환경 확장

본 연구의 단일 거리·단일 조명·단일 작업자·소수 재질 학습 데이터를 다거리(200, 500, 1000, 2000 mm), 다조명(실내 형광등 / 직사광 / 어두운 환경), 다작업자로 확장하여 환경

일반화 능력을 정량적으로 검증하는 후속 연구가 필요하다.

5.4.2 F5 변별력 확보를 위한 극단 시나리오

F5 (Measurement Rate)의 입력 채널 가치는 더 극단적인 신호 손실 환경에서 검증되어야 한다. 센서 물리적 가림(불투명 테이프, 손가락 등), 강한 IR 간섭원 동시 동작, 직사광 노출 등 본 연구에서 다루지 않은 outlier 환경의 추가가 향후 과제이다.

5.4.3 모델 구조 개선

본 연구는 6-feature MLP 구조를 채택하였으나, 다음 방향의 개선이 가능하다: (i) Quantization-aware training 도입으로 INT8 양자화에 따른 정확도 손실 최소화, (ii) sliding window 크기(현 $W = 20$) 확대로 시간 동역학 학습 강화, (iii) recurrent 구조(LSTM, GRU) 검토로 시간 의존성의 명시적 모델링. 본 연구의 추론 시간 측정 결과(mean 35.32 μ s, max 38.10 μ s)가 TinyML 추론 목표 시간 500 μ s의 7~8% 수준(200 Hz 제어 루프 예산 5 ms 기준 약 0.7%)임을 고려할 때, 더 큰 모델 구조 도입의 실시간성 여지는 충분하다.

5.4.4 다중 센서 직접 융합

본 연구는 HC-SR04 ultrasonic 센서를 F4 (sensor disagreement) feature 산출에만 활용하였다. 향후 ultrasonic을 측정 채널로 직접 융합(multi-rate KF)하여 광학(VL53L0X)과 음향(HC-SR04) 두 측정 원리의 외란 비대칭성을 능동적으로 활용하는 구조가 검토 가치가 있다.

5.4.5 실차 적용 검증

본 연구는 2WD 모형 로봇 + 단방향 직선 주행 + 합판 도로의 통제된 환경에서 수행되었다. 실 차량 규모의 주차 보조 시스템 + 다축 거동 + 외부 환경 조건(외부 조명, 노면 진동, EMI 등) 하에서의 일반화 검증이 후속 연구 과제이다.

5.4.6 더 긴 외란 시나리오에서의 $R^{\wedge}$ 회복 속도 차이 검증

본 연구의 E3 시나리오는 외란 구간이 평균 약 1초 내외로 짧아, TinyML-AKF의 R 점진 감소 패턴이 위치 추정 RMSE로 누적되지 않았다. 더 긴 외란(예: 3~5초) 또는 연속 외란 시나리오에서는 R 회복 속도의 차이가 위치 추정 정확도에 영향을 미칠 가능성이 있으며, 본 가설의 검증이 후속 연구 과제이다.

5.5 결론 및 기여

본 연구는 STM32F446RE MCU 환경에서 TinyML 기반 Adaptive Kalman Filter (TinyML-AKF)를 구현하고, Fixed KF 및 Covariance Matching 기반 AKF (CM-AKF)와의 3-way 비교를 통해 실시간성, 측정 노이즈 적응성, 학습 분포 외 일반화 능력을 검증하였다. 30분 $\times$ 3 run의 정적 안정성 시나리오(E4)에서 누적 242,992회 추론의 평균 35.32 μ s (200 Hz 제어 루프 예산 5 ms의 약 0.71%) 및 표준편차 0.007 μ s로 200 Hz 제어 루프 내 결정론적 실시간 동작을 입증하였으며 (RQ1), 알루미늄 동적 차단 시나리오(E3)에서 합성 데이터로 보고되어 온 CM-AKF의 stuck sensor 한계가 실물 환경에서 재현되는 한편(2차 5 run cm_R clamp 100% 도달), TinyML-AKF가 다변량 feature 활용을 통해 차단 이탈 후 R 추정값을 CM-AKF 대비 약 2.7배 빠르게 회복시키는 차별적 거동을 확인하였다. 단 본 실험 조건의 짧은 외란 구간(평균 약 1초)에서 위치 추정 RMSE는 두 적응형 알고리즘이 동등 수준이었다 (RQ2 동적 outlier 측면 및 RQ3). 미지 표면 시나리오(E5)에서는 TinyML-AKF가 학습 분포 외 조건에서도 R 클램프 한계에 도달하지 않고 발산 없이 일반화됨을 확인하였다.

본 연구의 기여는 다음 세 가지이다.

첫째, MCU 환경 TinyML 실시간성의 정량 입증. 30분 $\times$ 3 run $\times$ 200 Hz 누적 측정 (242,992회 추론, 360,000 loops $\times$ 3)에서 추론 시간 표준편차 0.007 μ s의 결정론적 동작을 입증하여, TinyML 기반 R 적응 메커니즘이 200 Hz 제어 루프 시간 제약 내에서 실시간 적용 가능성을 보였다.

둘째, CM-AKF stuck sensor 한계의 실물 재현과 적응형 R 추정의 효과 입증. 2.2.3절에서 합성 데이터로만 보고되어 온 $R \rightarrow K \rightarrow P \rightarrow R$ 순환 한계를 E3 알루미늄 동적 차단 시나리오에서 실측 재현하였으며(2차 5 run cm_R clamp 100% 도달), CM-AKF와 TinyML-AKF가 Fixed KF 대비 약 1/3 수준의 위치 추정 RMSE(약 14~17 mm vs Fixed 45 mm)를 달성함을 보였다. TinyML-AKF는 차단 이탈 후 R 추정값이 CM-AKF 대비 약 2.7배 빠르게 회복되는 거동(60 ms vs 160 ms)을 통해 잔차 단일 통계만으로 불가능한 R 적응 거동을 보였으며, 이는 다변량 feature 활용의 직접 증거이다. 단 본 실험 조건의 짧은 외란 구간(평균 약 1초)에서는 R 회복 속도의 차이가 위치 추정 RMSE로 누적되지 않았다 (5.4절 향후 더 긴 외란 시나리오에서의 검증 필요).

셋째, 다변량 feature 활용의 정당성에 대한 실측 근거. 잔차 통계만을 사용하는 기존 적응 기법으로는 표면의 광학적 특이성을 식별하기 어려운 영역이 존재함을 실측으로 확인하였다. E2에서 측정된 표면별 signal_rate는 가시광 반사율과 단조 관계에 있지 않아(가시광상 거의 투명한 투명 아크릴 13.2 Mcps가 가시광 흡수체인 검정 우드락 11.1 Mcps보다 높음), 사람이 직관적 규칙으로 noise 환경을 예측할 수 없는 영역임을 보였다(5.2.3절). 이러한 표면에서는 잔차 통계만 사용하는 ablation 모델의 R 적응이 불충분하여 위치 추정 RMSE가 열위를 보인

반면(5.2.2절), `signal_rate`를 포함한 다변량 모델은 발산 없이 동작하였다. 단, 이 대비는 측정 차수와 GT 정의가 다른 조건 간 비교이므로 절대 수치가 아닌 정성적 방향성으로 해석한다. 이는 잔차 통계 외의 센서 신호 품질 feature가 ToF 기반 적응형 필터에서 대체 불가능한 정보를 제공함을 시사하며, RQ3에서 제기한 다변량 feature 활용의 정당성을 뒷받침한다.

본 연구의 결과는 저속 주차 보조 시스템과 같이 200 Hz 정밀 거리 추정이 요구되는 임베디드 응용 영역에서, MCU 환경의 TinyML 기반 적응형 필터의 실용 적용 가능성을 정량적으로 뒷받침한다.

참고문헌

- [1] R. E. Kalman, "A new approach to linear filtering and prediction problems," *Journal of Basic Engineering*, vol. 82, pp. 35-45, 1960.
- [2] R. K. Mehra, "On the identification of variances and adaptive kalman filtering," *IEEE Transactions on Automatic Control*, vol. 15, no. 2, pp. 175-184, 1970.
- [3] A. H. Mohamed and K. P. Schwarz, "Adaptive kalman filtering for INS/GPS," *Journal of Geodesy*, vol. 73, pp. 193-203, 1999.
- [4] D. Nadalini, M. Rusci, L. Benini, and F. Conti, "Reduced precision floating-point optimization for deep neural network on-device learning on microcontrollers," *arXiv:2305.19167*, 2023.
- [5] V. J. Reddi et al., "Widening access to applied machine learning with TinyML," *arXiv:2106.04008*, 2021.
- [6] G. Welch and G. Bishop, "An introduction to the kalman filter," *University of North Carolina at Chapel Hill*, TR 95-041, 2006.
- [7] S. J. Julier and J. K. Uhlmann, "Unscented filtering and nonlinear estimation," *Proceedings of the IEEE*, vol. 92, no. 3, pp. 401-422, 2004.
- [8] Z. Zhou, D. Liu, S. Guo, and Y. Yang, "Robust indoor localization via conformal methods and variational bayesian adaptive filtering," *arXiv:2505.08639*, 2025.
- [9] G. Revach, N. Shlezinger, X. Ni, A. L. Escoriza, R. J. G. van Sloun, and Y. C. Eldar, "KalmanNet: neural network aided kalman filtering for partially known dynamics," *IEEE Transactions on Signal Processing*, vol. 70, pp. 1532-1547, 2022.
- [10] A. Barros et al., "Adaptive extended kalman filtering for battery state of charge estimation on STM32," *IEEE Embedded Systems Letters*, 2025.
- [11] A. K. T. RamaNaik and S. Majumder, "Error-aware adaptive kalman filtering for accurate state of charge estimation in electric vehicles," 2025.
- [12] J. Kim, M. Seong, and J. W. Choi, "CRT-fusion: camera, radar, temporal fusion using motion information for 3D object detection," *arXiv:2411.03013*, 2024.
- [13] C. Banbury et al., "MLPerf tiny benchmark," *arXiv:2106.07597*, 2021.
- [14] STMicroelectronics, "X-CUBE-AI: AI expansion pack for STM32CubeMX," Available: <https://www.st.com/en/embedded-software/x-cube-ai.html>.
- [15] K. A. Myers and B. D. Tapley, "Adaptive sequential estimation with unknown noise statistics," *IEEE Transactions on Automatic Control*, vol. 21, no. 4, pp. 520-523, 1976.
- [16] S. Sarkka and A. Nummenmaa, "Recursive noise adaptive kalman filtering by variational bayesian approximations," *IEEE Transactions on Automatic Control*, vol. 54, no. 3, pp. 596-600, 2009.
- [17] C. Banbury et al., "MicroNets: neural network architectures for deploying TinyML applications on commodity microcontrollers," *MLSys*, 2021.